ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2024 – 2025

ΜΑΘΗΜΑ: ΣΤΑΤΙΣΤΙΚΗ ΣΤΗΝ ΠΛΗΡΟΦΟΡΙΚΗ

1η Άσκηση

Ερώτηση 1.

- **a.**

<u>Για τα δεδομένα Ι:</u>

Δεδομένα Ι									
30.3	31.0	31.1	32.1	32.6	32.7	33.4	33.6	34.2	34.5

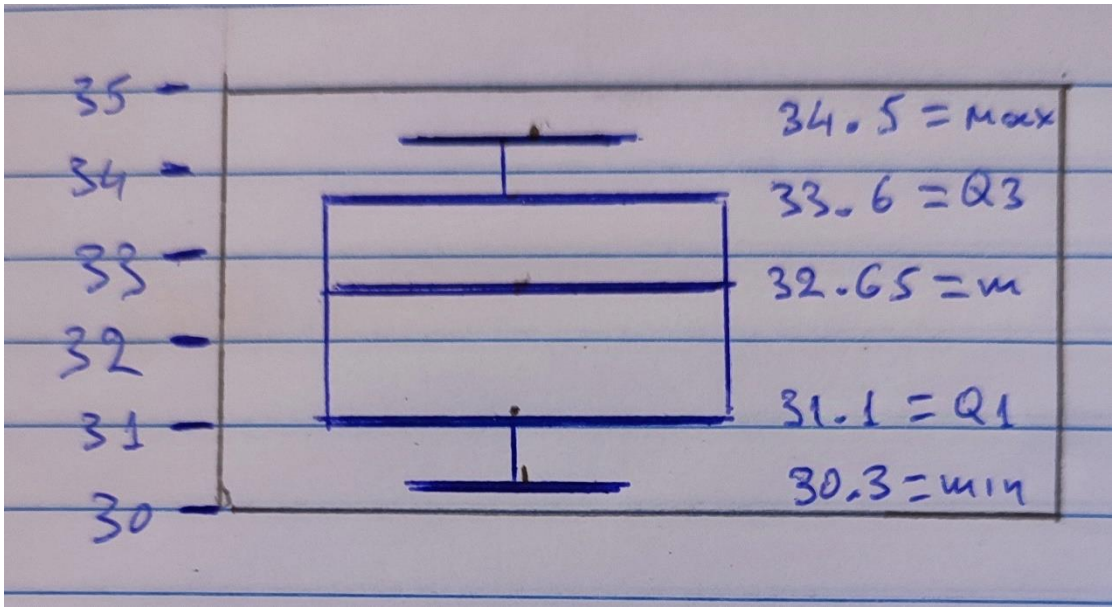
<u>Stemplot:</u>

Στέλεχος/μίσχος (stem)	Φύλλο
30	3
31	0 1
32	1 6 7
33	4 6
34	2 5

<u>Boxplot</u>

Για το boxplot θα υπολογίσουμε τους πέντε αριθμούς κάθε ομάδας δεδομένων: ελάχιστο (**min**), πρώτο τεταρτημόριο (**Q1**), διάμεση τιμή (**m**), τρίτο τεταρτημόριο (**Q3**), και μέγιστο (**max**).

Έχουμε: min=30.3, m=(32.6+32.7)/2=32.65, Q1=31.1, Q3=33.6, max=34.5



Για τα δεδομένα II:

Δεδομένα II									
0.0	0.0	0.2	0.8	1.2	1.4	3.2	4.2	6.4	9.0

Stemplot:

Στέλεχος/μίσχος (stem)	Φύλλο
0	0 0 2 8
1	2 4
2	
3	2
4	2
5	
6	4
7	
8	
9	0

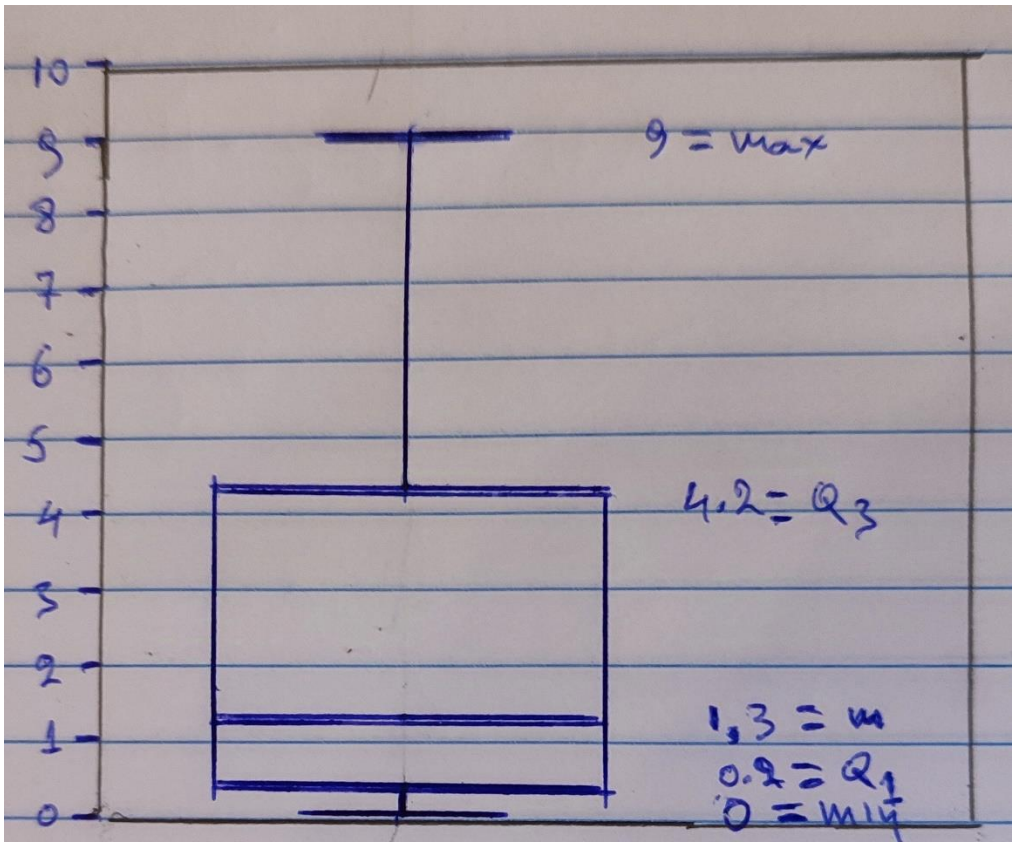
Ή

Στέλεχος/μίσχος (stem)	Φύλλο
0-1	0 0 2 8 2 4
2-3	2
4-5	2
6-7	4
8-9	0

Boxplot

Για το boxplot θα υπολογίσουμε τους πέντε αριθμούς κάθε ομάδας δεδομένων: ελάχιστο (**min**), πρώτο τεταρτημόριο (**Q1**), διάμεση τιμή (**m**), τρίτο τεταρτημόριο (**Q3**), και μέγιστο (**max**).

Έχουμε: min=0, m=(1.2+1.4)/2=1.3, Q1=0.2, Q3=4.2, max=9



Για τα δεδομένα III:

Δεδομένα III									
0	1	6	8	10	13	15	16	17	17
18	18	20	20	21	25	26	30	35	39
40	41	43	44	46	48	52	54	58	59
59	60	66	81	86	87	88	89	94	96

Stemplot:

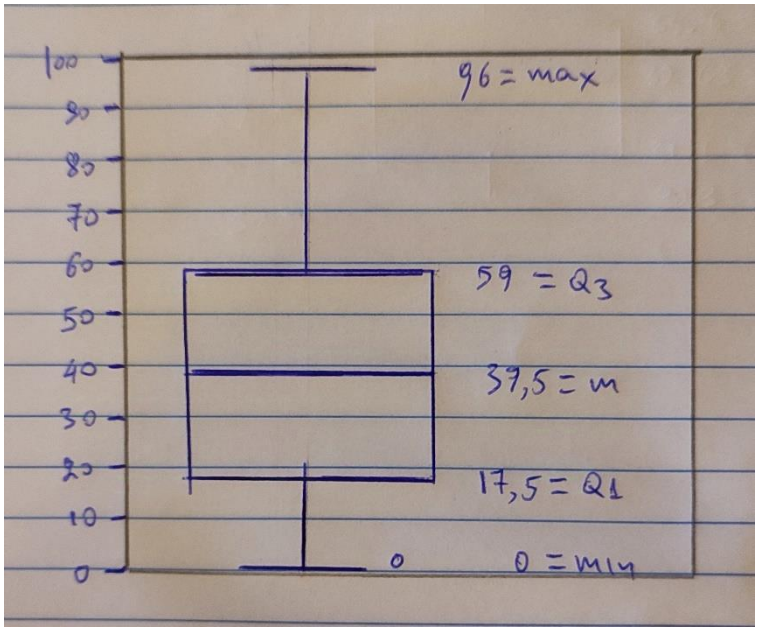
Καθώς είναι πολλά δεδομένα, ια να το απλοποιήσουμε, μπορούμε να χωρίσουμε τα δεδομένα ανά δεκάδες, κρατώντας τα πρώτα ψηφία ως "stem" και τα τελευταία ως "leaf".

Στέλεχος/μίσχος (stem)	Φύλλο
0	0 1 6 8
1	0 3 5 6 7 7 8 8
2	0 0 1 5 6
3	0 5 9
4	0 1 3 4 6 8
5	2 4 8 9 9
6	0 6
7	
8	1 6 7 8 9
9	4 6

Boxplot

Για το boxplot θα υπολογίσουμε τους πέντε αριθμούς κάθε ομάδας δεδομένων: ελάχιστο (**min**), πρώτο τεταρτημόριο (**Q1**), διάμεση τιμή (**m**), τρίτο τεταρτημόριο (**Q3**), και μέγιστο (**max**).

Έχουμε: min=0, m=(39+40/2)=39.5, Q1=(17+18)/2=17.5, Q3=(59+59)/2=59, max=96



- **b.** Λαμβάνοντας υπόψη ότι:
  - Η μέση τιμή και τυπική απόκλιση, χρησιμοποιούνται συνήθως για συμμετρικές κατανομές χωρίς ακραίες τιμές.
  - Η σύνοψη των πέντε αριθμών, είναι καταλληλότερη για ασύμμετρες κατανομές ή κατανομές με ακραίες τιμές.

  Έχουμε τα εξής:

  <u>Ομάδα Δεδομένων I</u>

  Μέση Τιμή: 32.55, Τυπική Απόκλιση: 1.41

  Τα δεδομένα είναι αρκετά συμμετρικά γύρω από τη μέση τιμή και οι τιμές κυμαίνονται σε μικρό εύρος, χωρίς εμφανείς ακραίες τιμές. Έτσι **η μέση τιμή και τυπική απόκλιση** μπορούν να συνοψίσουν επαρκώς αυτήν την κατανομή.

  <u>Ομάδα Δεδομένων II</u>

  Μέση Τιμή: 2.64, Τυπική Απόκλιση: 3.05

  Τα δεδομένα δεν είναι ομοιόμορφα κατανεμημένα γύρω από την μέση τιμή, καθώς υπάρχουν πολύ περισσότερες χαμηλές τιμές απ’ ό,τι υψηλές, επομένως **η σύνοψη των 5 αριθμών** αποτελεί καλύτερη αναπαράσταση καθώς μας δίνει καλύτερη εικόνα για την κατανομή των τιμών.

  <u>Ομάδα Δεδομένων III</u>

  Μέση Τιμή: 41.15, Τυπική Απόκλιση: 28.26

  Τα δεδομένα είναι ομοιόμορφα κατανεμημένα γύρω από την μέση τιμή, επομένως η μέση τιμή και η τυπική απόκλιση συνοψίζουν καλά την κατανομή, παρ' όλ' αυτά, επειδή το πλήθος των δεδομένων είναι μεγάλο, **η σύνοψη των 5 αριθμών** δίνει ακριβέστερες πληροφορίες (min, Q1, m, Q3, max).

- **c.** Από τον κανόνα 68-95-99.7, γνωρίζουμε ότι: στην κανονική κατανομή ισχύουν τα εξής:

  ● το 68% των παρατηρήσεων βρίσκεται στο διάστημα $(\mu - \sigma, \mu + \sigma)$

  ● το 95% των παρατηρήσεων βρίσκεται στο διάστημα $(\mu - 2\sigma, \mu + 2\sigma)$

  ● το 99.5% των παρατηρήσεων βρίσκεται στο διάστημα $(\mu - 3\sigma, \mu + 3\sigma)$,

  όπου μ = μέση τιμή και σ = τυπική απόκλιση.

  <u>Για την Ομάδα Δεδομένων I</u>

  Έχουμε $\mu=32.55$ και $\sigma=1.41$

  Παρατηρούμε ότι στο διάστημα (31.14, 33.96) δηλαδή το αντίστοιχο $(\mu - \sigma, \mu + \sigma)$ βρίσκονται οι 5 από τις 10 παρατηρήσεις, ποσοστό της τάξης του 50% έναντι του αναμενόμενου 68%. Επίσης για τα αντίστοιχα διαστήματα $(\mu-2\sigma, \mu+2\sigma)$ δηλαδή στο διάστημα (29.73, 35.37) βρίσκεται το 100% των

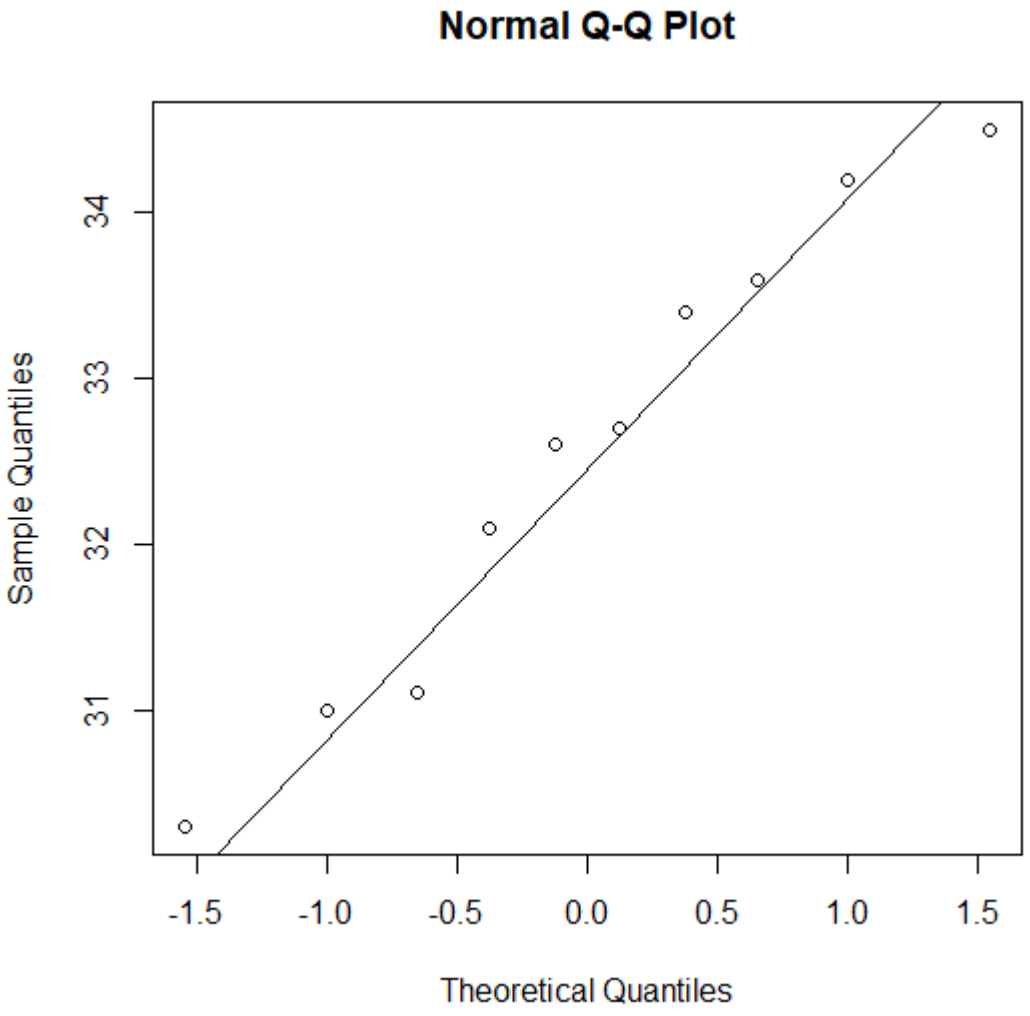
παρατηρήσεων έναντι του 95% της Κανονικής Κατανομής, και στο (μ–3σ, μ+3σ) δηλαδή στο διάστημα (28.32, 36.77) βρίσκεται και εκεί το 100% αυτών έναντι του 99.5%**.**

Έτσι η προσέγγιση της κατανομής των Δεδομένων Ι από μια καμπύλη πυκνότητας κανονικής κατανομής, δεν θα ήταν απόλυτη αλλά **σε ικανοποιητικό επίπεδο προσέγγισης**.

Αυτό προκύπτει άλλωστε και από την γραφική παράσταση των δειγματικών ποσοστημορίων ως προς τα θεωρητικά ποσοστημόρια της Κανονικής Κατανομής QQ PLOT. Όσο πιο κοντά στην γραμμή, που αναπαριστά τα θεωρητικά ποσοστημόρια, είναι τα σημεία, που με την σειρά τους αναπαριστούν τα δειγματικά ποσοστημόρια, τόσο καλύτερη προσαρμογή έχουμε. Με χρήση των παρακάτω εντολών της R:

```
dataI <- c(30.3, 31.0, 31.1, 32.1, 32.6, 32.7, 33.4, 33.6, 34.2, 34.5)
qqnorm(dataI)
qqline(dataI)
```

Προκύπτει:



Από το παραπάνω σχήμα προκύπτει πως τα Δεδομένα Ι θα προσεγγίζονταν επαρκώς από την καμπύλη πυκνότητας της κανονικής κατανομής

<u>Για την Ομάδα Δεδομένων ΙΙ</u>

Έχουμε μ=2.64 και σ=3.05

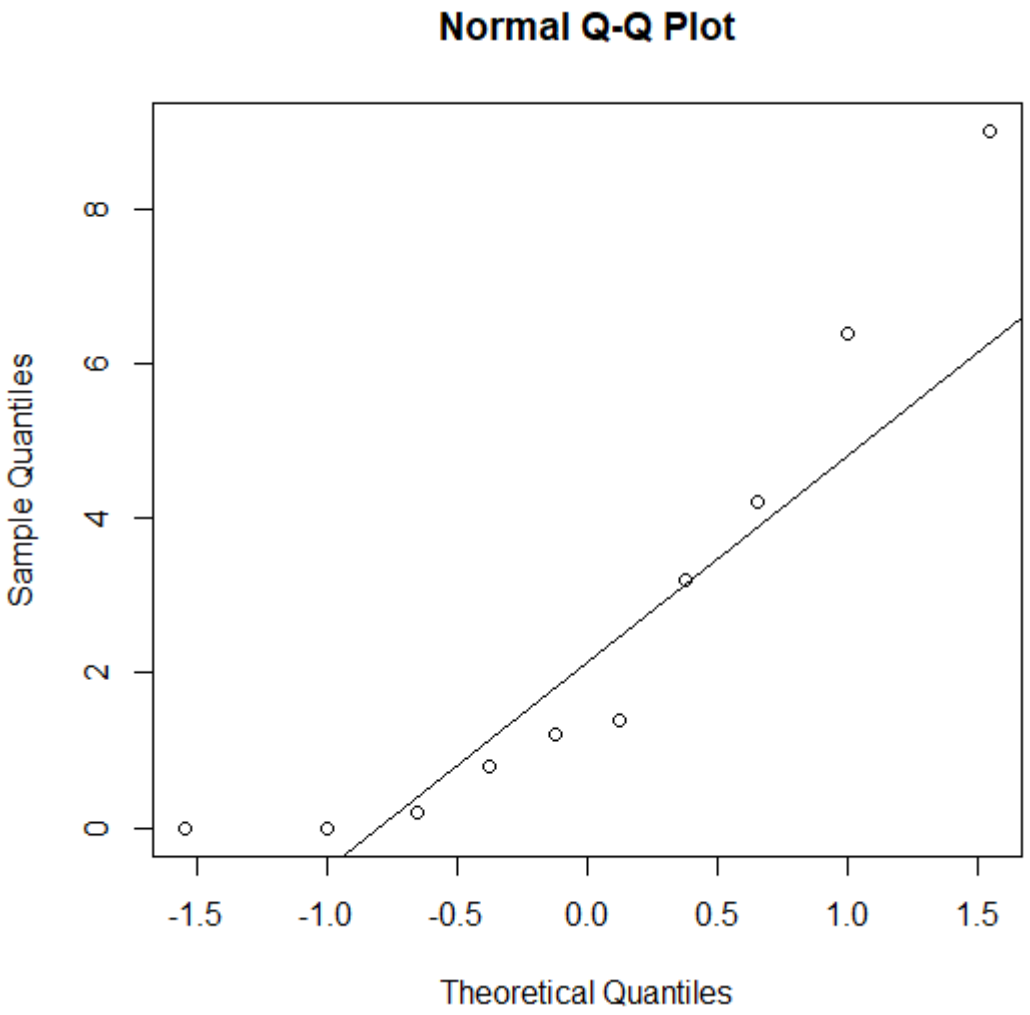
Παρατηρούμε ότι στο διάστημα (-0.41, 5.69) δηλαδή το αντίστοιχο (μ – σ, μ + σ) βρίσκονται οι 8 από τις 10 παρατηρήσεις, ποσοστό της τάξης του 80% έναντι του αναμενόμενου 68%. Επίσης για τα αντίστοιχα διαστήματα (μ–2σ, μ+2σ) δηλαδή στο διάστημα (-3.46, 8.74) βρίσκεται το 90% των παρατηρήσεων έναντι του 95% της Κανονικής Κατανομής, και στο (μ–3σ, μ+3σ) δηλαδή στο διάστημα (-6.51, 11,79) βρίσκεται το 100% αυτών έναντι του 99.5%**.**

Έτσι η προσέγγιση της κατανομής των Δεδομένων ΙΙ από μια καμπύλη πυκνότητας κανονικής κατανομής, θα ήταν σε **λιγότερο ικανοποιητικό επίπεδο προσέγγισης**.

Με χρήση των παρακάτω εντολών της R:

```
dataII <- c(0.0, 0.0, 0.2, 0.8, 1.2, 1.4, 3.2, 4.2, 6.4, 9.0)
qqnorm(dataII)
qqline(dataII)
```

Προκύπτει:



<u>Για την Ομάδα Δεδομένων ΙΙΙ</u>

Έχουμε μ=41.15 και σ=28.26

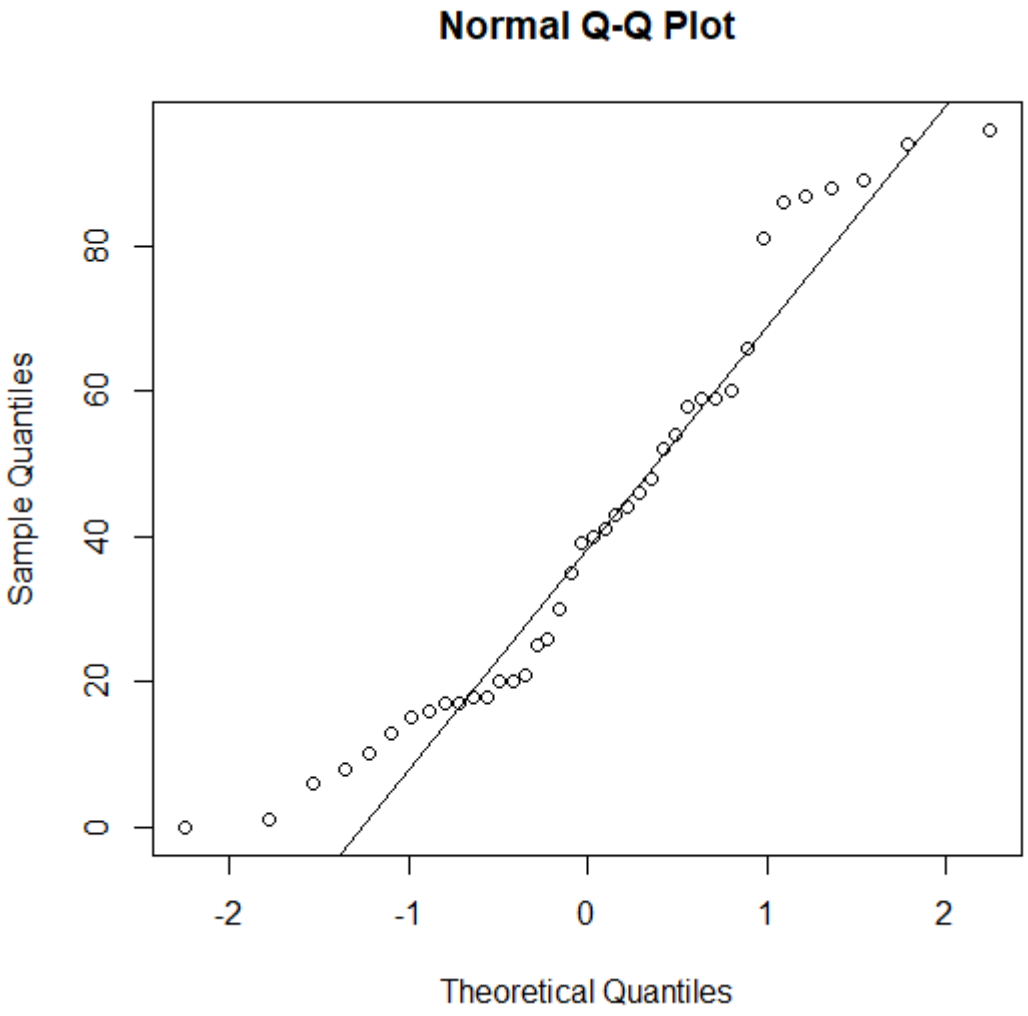
Παρατηρούμε ότι στο διάστημα (12.89, 69.41) δηλαδή το αντίστοιχο (μ – σ, μ + σ) βρίσκονται οι 28 από τις 40 παρατηρήσεις, ποσοστό της τάξης του 70% έναντι του αναμενόμενου 68%. Επίσης για τα αντίστοιχα διαστήματα (μ–2σ, μ+2σ) δηλαδή στο διάστημα (-15.37, 97.67) βρίσκεται το 100% των παρατηρήσεων έναντι του 95% της Κανονικής Κατανομής, και στο (μ–3σ, μ+3σ) βρίσκεται το 100% αυτών έναντι του 99.5%**.**

Έτσι η προσέγγιση της κατανομής των Δεδομένων III από μια καμπύλη πυκνότητας κανονικής κατανομής **δεν θα ήταν ιδιαίτερα ακριβής**.

Με χρήση των παρακάτω εντολών της R:

```
dataIII <- c(0, 1, 6, 8, 10, 13, 15, 16, 17, 17, 18, 18, 20, 20, 21, 25, 26, 30, 35, 39,
40, 41, 43, 44, 46, 48, 52, 54, 58, 59, 59, 60, 66, 81, 86, 87, 88, 89, 94, 96)
qqnorm(dataIII)
qqline(dataIII)
```

Προκύπτει:



Ερώτηση 2.

- **a.** Αναζητήσαμε στην Ελληνική Στατιστική Αρχή (https://www.statistics.gr/) δεδομένα για τις γεννήσεις, τους θανάτους και τους γάμους στην Ελλάδα και βρήκαμε τα παρακάτω αρχεία:

Γεννήσεις - Απόλυτοι αριθμοί και ποσοστά (1932 - 2023)

Θάνατοι - Απόλυτοι αριθμοί και ποσοστά (1932 - 2022)

Γάμοι - Απόλυτοι αριθμοί και ποσοστά (1932 - 2023)

Με συνδυασμό των δεδομένων από αυτά τα αρχεία δημιουργήσαμε ένα csv αρχείο με όνομα **data.csv** που περιέχει τις παρακάτω στήλες:

year, births_per_1000, deaths_per_1000, marriages_per_1000

όπου year είναι η χρονιά από το 1932 έως το 2021, births_per_1000, deaths_per_1000 και weddings_per_1000, είναι αντίστοιχα οι γεννήσεις, οι θάνατοι και οι γάμοι ανά 1000 κατοίκους. Ένα **απόσπασμα** του αρχείου φαίνεται παρακάτω:

year	births_per_1000	deaths_per_1000	marriages_per_1000
1932	28,4	17,97	6,0
1933	28,6	16,82	7,0
1934	31,1	14,96	7,0
1935	28,2	14,83	6,7
1936	27,9	15,14	5,6
1937	26,2	15,04	6,5
1938	25,9	13,17	6,5
1939	24,8	13,91	6,6
1940	24,5	12,82	4,5
1955	19,4	6,88	8,3
1956	19,7	7,40	6,9
1957	19,3	7,62	8,5

Παρατηρούμε ότι για τα έτη 1941 έως 1954 δεν υπάρχουν στοιχεία! Έτσι οι συνολικές εγγραφές του αρχείου είναι 76.

- **b.** Κατηγορική μεταβλητή είναι το **έτος**. Ποσοτικές μεταβλητές είναι: **Γεννήσεις ανά 1000 κατοίκους, Θάνατοι ανά 1000 κατοίκους, Γάμοι ανά 1000 κατοίκους**.

- **c.** Κατανομές των μεταβλητών σε γραφική μορφή

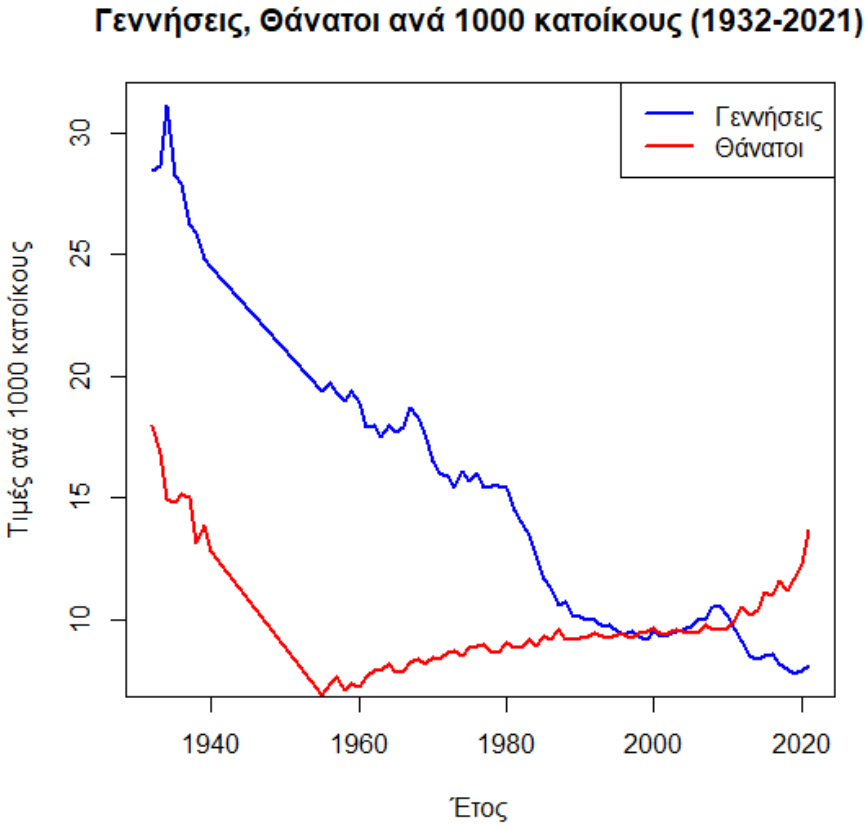
Οι παρακάτω εντολές δίνονται στο περιβάλλον της R:

```
# Φόρτωση δεδομένων, το αρχείο λέγεται data.csv και είναι στο root του C
data <- read.csv("c:/data.csv", header = TRUE, sep = ",", fill = TRUE)

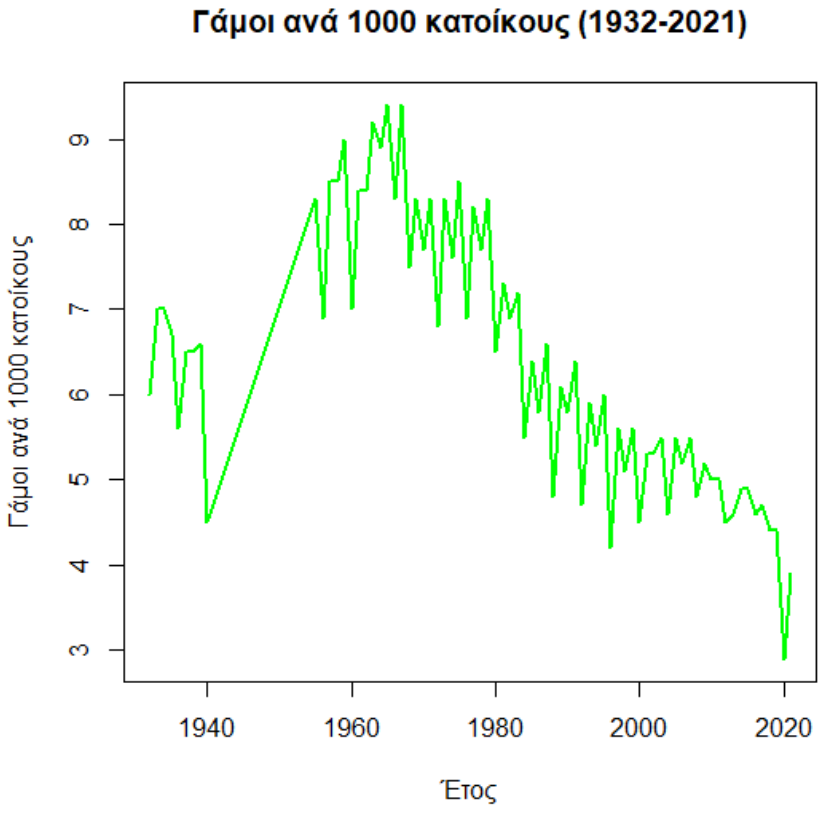
# Δημιουργία του βασικού γραφήματος με τις γεννήσεις
plot(data$year, data$births_per_1000, type = "l", col = "blue",
     xlab = "Έτος", ylab = "Τιμές ανά 1000 κατοίκους",
     main = "Γεννήσεις, Θάνατοι ανά 1000 κατοίκους (1932-2021)")

# Προσθήκη της γραμμής για τους θανάτους
lines(data$year, data$deaths_per_1000, col = "red")

# Προσθήκη υπομνήματος για τις καμπύλες
legend("topright", legend = c("Γεννήσεις", "Θάνατοι"),col = c("blue", "red"))
```




```
# Γραφική παράσταση για τους γάμους ανά 1000 κατοίκους
plot(data$year, data$marriages_per_1000, type = "l", col = "green",
     xlab = "Έτος", ylab = "Γάμοι ανά 1000 κατοίκους",
     main = "Γάμοι ανά 1000 κατοίκους (1932-2021)")
```



Στις παραπάνω κατανομές είναι εμφανές το «χάσμα» που υπάρχει ανάμεσα στα έτη 1941 έως 1954 όπου όπως αναφέραμε παραπάνω, δεν υπάρχουν στοιχεία.

Παρατηρούμε την εξαιρετικά φθίνουσα τάση των γεννήσεων, παρά τις περιόδους με διακυμάνσεις, η συνολική τάση είναι πτωτική. Πιθανοί λόγοι είναι η αστικοποίηση του πληθυσμού και οι αλλαγές των κοινωνικών αντιλήψεων ιδιαίτερα μετά την δεκαετία του 1980. Στα μέσα της δεκαετίας του 2000, προσπάθησε η Πολιτεία να δώσει κάποια κίνητρα για περισσότερες γεννήσεις, αλλά μετά ήρθε η οικονομική κρίση, αυτό αποτυπώνεται στο διάγραμμα των γεννήσεων.

Η τάση στους θανάτους αρχικά εμφανίζει μείωση, καθώς οι βελτιώσεις στον τομέα της υγείας και της ιατρικής συμβάλλουν στη μείωση της θνησιμότητας. Ωστόσο, η γήρανση του πληθυσμού οδηγεί σε αυξημένα ποσοστά θανάτων σε μετέπειτα έτη, καθώς το μεγαλύτερο ποσοστό ηλικιωμένων είναι πιο επιρρεπές στη θνησιμότητα.

Η κατανομή των γάμων παρουσιάζει αύξηση μετά τον Β Παγκόσμιο Πόλεμο, ενώ στην συνέχεια παρουσιάζει μείωση παρά τις διακυμάνσεις. Είναι πιθανόν οι πριονωτές διακυμάνσεις που παρατηρούνται να οφείλονται στην πρόληψη για τα δίσεκτα έτη. Κατά τα τελευταία χρόνια, η στάση απέναντι στο γάμο έχει αλλάξει, με πολλούς να επιλέγουν είτε να καθυστερούν είτε να αποφεύγουν το γάμο. Η οικονομική αβεβαιότητα αποθαρρύνει τους γάμους. Η νομοθεσία γύρω από τις σχέσεις, όπως η δυνατότητα για συμβιώσεις χωρίς γάμο και οι αλλαγές στη νομοθεσία για τα διαζύγια, μπορεί επίσης να έχουν επηρεάσει τον αριθμό των γάμων.

- **d.** Εκτελώντας τις παρακάτω εντολές στο περιβάλλον της R,

```
# Μέση τιμή και τυπική απόκλιση για κάθε μεταβλητή
sd_births <- sd(data$births_per_1000, na.rm = TRUE)
summary_births <- summary(data$births_per_1000)
sd_births
summary_births

sd_deaths <- sd(data$deaths_per_1000, na.rm = TRUE)
summary_deaths <- summary(data$deaths_per_1000)
sd_deaths
summary_deaths

sd_marriages <- sd(data$marriages_per_1000, na.rm = TRUE)
summary_marriages <- summary(data$marriages_per_1000)
sd_marriages
summary_marriages
```

Παίρνουμε τα παρακάτω αποτελέσματα:

Γεννήσεις

mean	sd	min	1st Qu.	median	3rd Qu	Max
14.51053	6.033519	7.800	9.575	13.100	17.925	31.100

Θάνατοι

mean	sd	min	1st Qu.	median	3rd Qu	Max
9.881711	2.260751	6.880	8.643	9.330	10.043	17.970

Γάμοι

mean	sd	min	1st Qu.	median	3rd Qu	Max
6.364474	1.550458	2.900	5.075	6.250	7.625	9.400

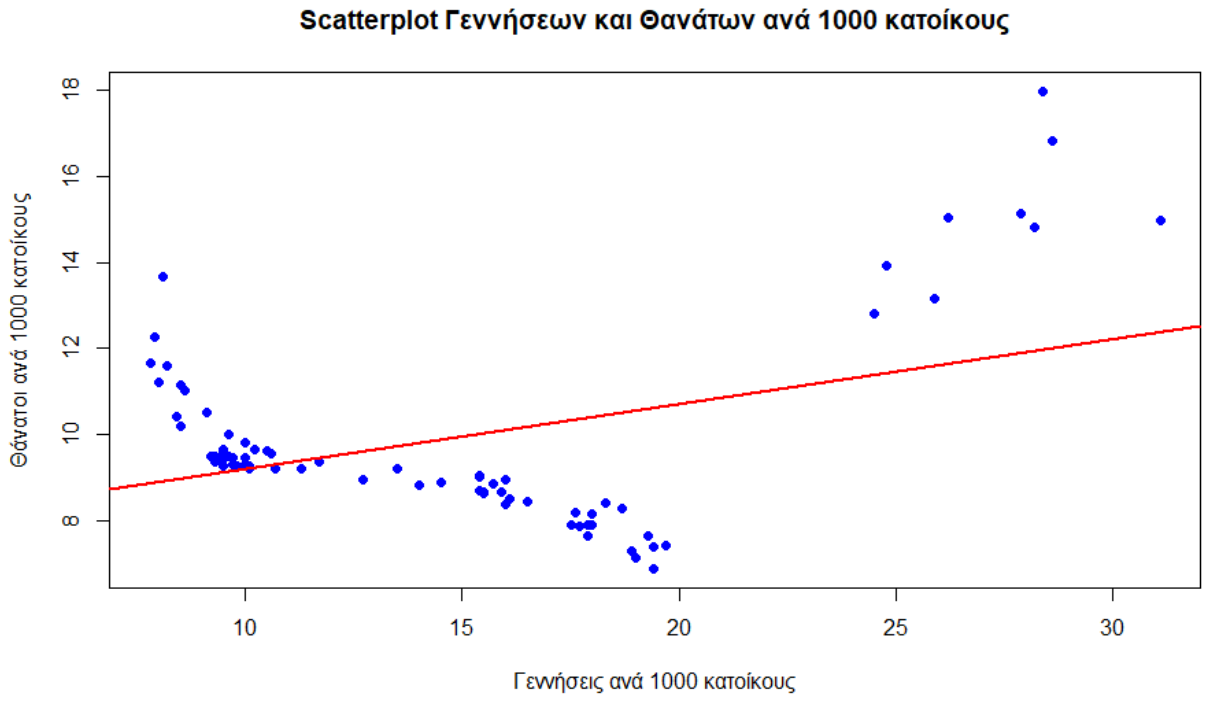
Στην περίπτωση των γεννήσεων η μέση τιμή είναι μεγαλύτερη από την διάμεσο και η τυπική απόκλιση είναι υψηλή. Η μέγιστη τιμή είναι αρκετά πιο πάνω από την μέση τιμή και η διαφορά μεταξύ του ελάχιστου και του μέγιστου δείχνει αρκετά μεγάλη διακύμανση, ενισχυόμενη από την τυπική απόκλιση. Για τη συγκεκριμένη κατανομή, θα προτείναμε την **σύνοψη των 5 αριθμών** καθώς υπάρχει μια ασυμμετρία και η χρήση μόνο της μέσης τιμής και της τυπικής απόκλισης θα μπορούσαν να παραπλανήσουν.

Για την περίπτωση των θανάτων παρατηρούμε ότι η μέση τιμή και η διάμεσος είναι κοντά και η τυπική απόκλιση δεν είναι αρκετά μεγάλη. Η χρήση **της μέσης τιμής και της τυπικής απόκλισης** μπορεί να δώσει μια αρκετά αντιπροσωπευτική εικόνα, καθώς δεν παρατηρούμε μεγάλη ασυμμετρία ούτε τιμές εξαιρετικά μεγάλες ή μικρές (ατυπικές). Όμως, αν θέλαμε μια πιο λεπτομερή περιγραφή της διασποράς και την επιρροή των ακραίων τιμών**, η σύνοψη των 5 αριθμών** μπορεί να προσφέρει αυτή την εικόνα, ειδικά λόγω του σχετικά υψηλού μέγιστου.

Για την περίπτωση των γάμων η μέση τιμή είναι πολύ κοντά στην διάμεσο και η τυπική απόκλιση είναι σχετικά μικρή το οποίο δείχνει ότι τα δεδομένα συγκεντρώνονται κοντά στη μέση τιμή. Σε αυτήν την περίπτωση, το ζεύγος **μέση τιμή - τυπική απόκλιση** μπορεί να δώσει μια καλή εικόνα.

- **e.** Επιλέγουμε τις δύο ποσοτικές μεταβλητές γεννήσεις και θανάτους και διερευνούμε την σχέση τους. Αρχικά δημιουργούμε το διάγραμμα διασποράς (scatterplot) και προσθέτουμε γραμμή παλινδρόμησης.

```
# Δημιουργία scatterplot για Γεννήσεις και Θανάτους
plot(data$births_per_1000, data$deaths_per_1000,
     xlab = "Γεννήσεις ανά 1000 κατοίκους",
     ylab = "Θάνατοι ανά 1000 κατοίκους",
     main = "Scatterplot Γεννήσεων και Θανάτων ανά 1000 κατοίκους",
     pch = 16, col = "blue")
# Εκτέλεση γραμμικής παλινδρόμησης
model <- lm(data$deaths_per_1000 ~ data$births_per_1000)
abline(model, col = "red") # Προσθήκη γραμμής παλινδρόμησης
```



```
Υπολογισμός συντελεστή συσχέτισης:
# Υπολογισμός συντελεστή συσχέτισης (Pearson)
correlation <- cor(data$births_per_1000, data$deaths_per_1000, use = "complete.obs")
cat("Συντελεστής Συσχέτισης:", correlation, "\n")
```

Συντελεστής Συσχέτισης: 0.4034351

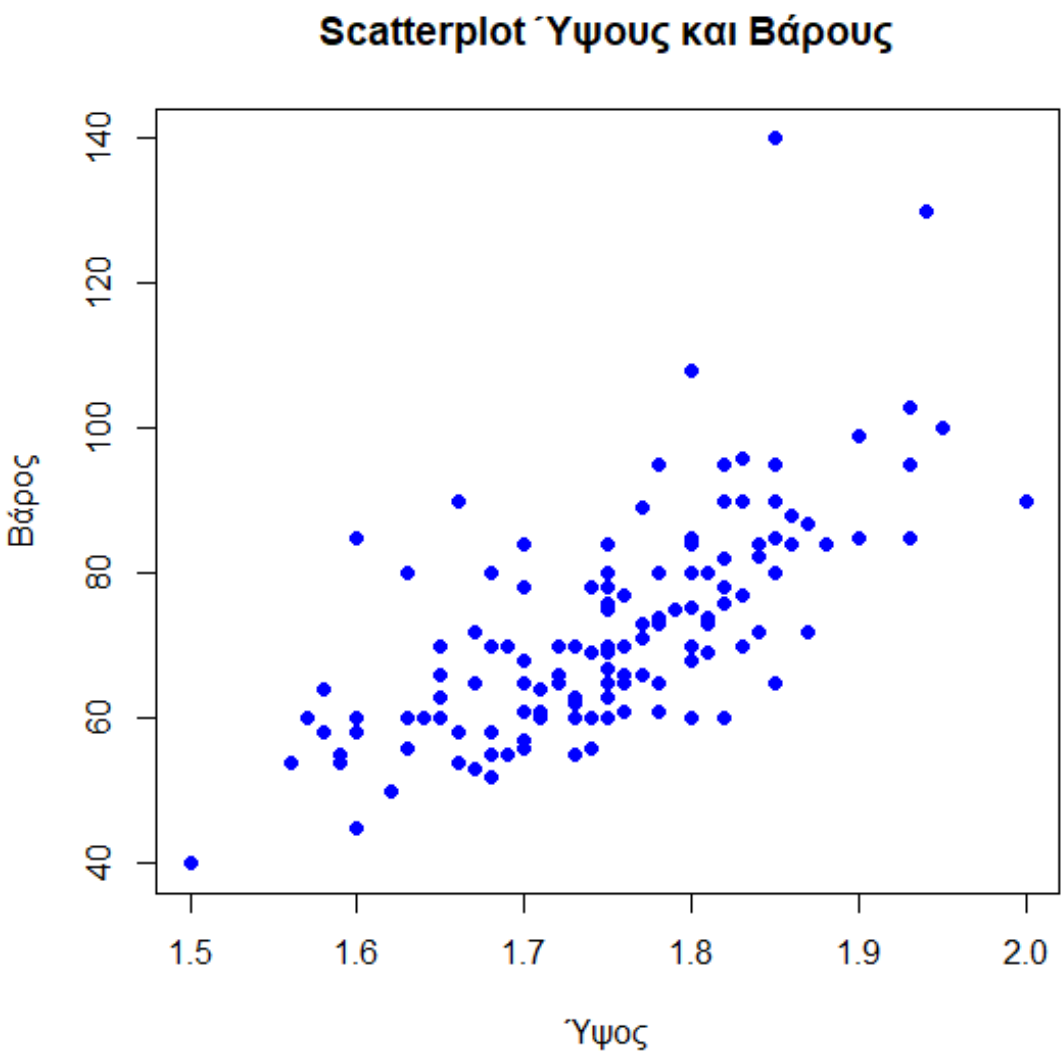
Από τα παραπάνω βλέπουμε ότι δεν υπάρχει ισχυρή συσχέτιση μεταξύ των δύο μεταβλητών.

Ερώτηση 3.

Οι ποσοτικές μεταβλητές που επιλέγουμε από το ερωτηματολόγιο για το συγκεκριμένο ερώτημα είναι το height και weight (ύψος και βάρος).

- **a.** Με τις παρακάτω εντολές έχουμε το scatter plot:

```
survey_data_2024 <- read.csv("c:/survey_data_2024.csv", header = TRUE, sep = ",")
plot(survey_data_2024 $height, survey_data_2024$weight,
     xlab = "Υψος",
     ylab = "Βάρος",
     main = "Scatterplot Ύψους και Βάρους",
     pch = 16, col = "blue")
```



Από το scatterplot παρατηρούμε ότι:

- Η μορφή είναι **γραμμική**.
- Η κατεύθυνση είναι **αύξουσα**.
- Η δύναμη της σχέσης είναι **θετική** και **ισχυρή**.

Το οποίο είναι αναμενόμενο επειδή συνήθως όσο πιο ψηλός είναι κάποιος τόσο πιο βαρύς είναι.

- **b.** Συντελεστής συσχέτισης:

```
r <- cor(survey_data_2024$height, survey_data_2024$weight, use = "complete.obs")
r
```

```
0.6811889
```

Παίρνουμε τον συντελεστή συσχέτισης **r = 0.6811889**

Γραμμική παλινδρόμηση ελαχίστων τετραγώνων:

```
m <- lm(survey_data_2024$weight ~ survey_data_2024$height)
summary(m)
```

Αποτελέσματα:

```
Call:
lm(formula = survey_data_2024$weight ~ survey_data_2024$height)

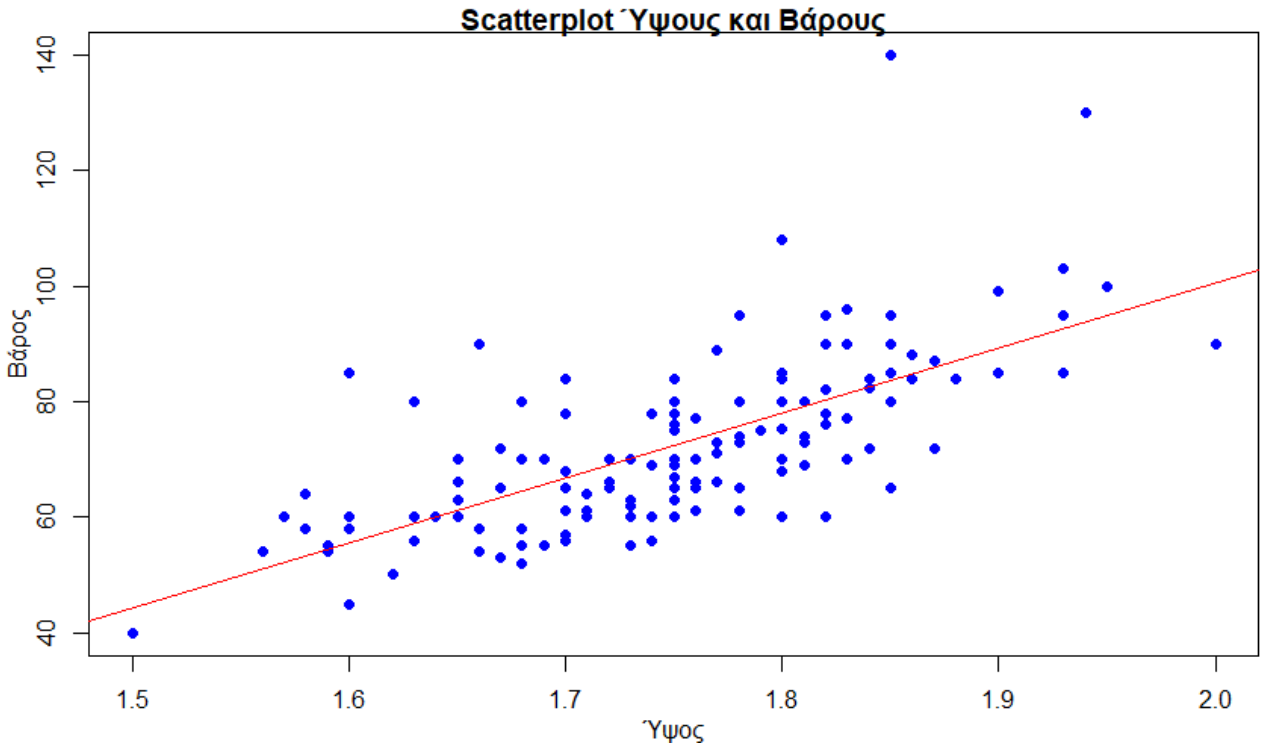
Residuals:
    Min      1Q  Median      3Q     Max
-20.288  -7.776  -1.705   4.923  56.329

Coefficients:
                         Estimate Std. Error t value Pr(>|t|)
(Intercept)              -124.91      18.35  -6.808 3.03e-10 ***
survey_data_2024$height   112.75      10.47  10.771  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 11.01 on 134 degrees of freedom
  (1 observation deleted due to missingness)
Multiple R-squared:  0.464,     Adjusted R-squared:   0.46
F-statistic:   116 on 1 and 134 DF,  p-value: < 2.2e-16
```

Μέσω των εντολών, έχουμε στη μεταβλητή m τους συντελεστές της γραμμικής συνάρτησης που ελαχιστοποιεί τα τετράγωνα των αποστάσεων μεταξύ σημείων και ευθείας. Επίσης, τοποθετούμε στο scatterplot μας με το abline τη γραμμή.

```
abline(m, col = "red")
```


Scatterplot Ύψους και Βάρους
Βάρος
40
60
80
100
120
140
1.5
1.6
1.7
1.8
1.9
2.0
Ύψος