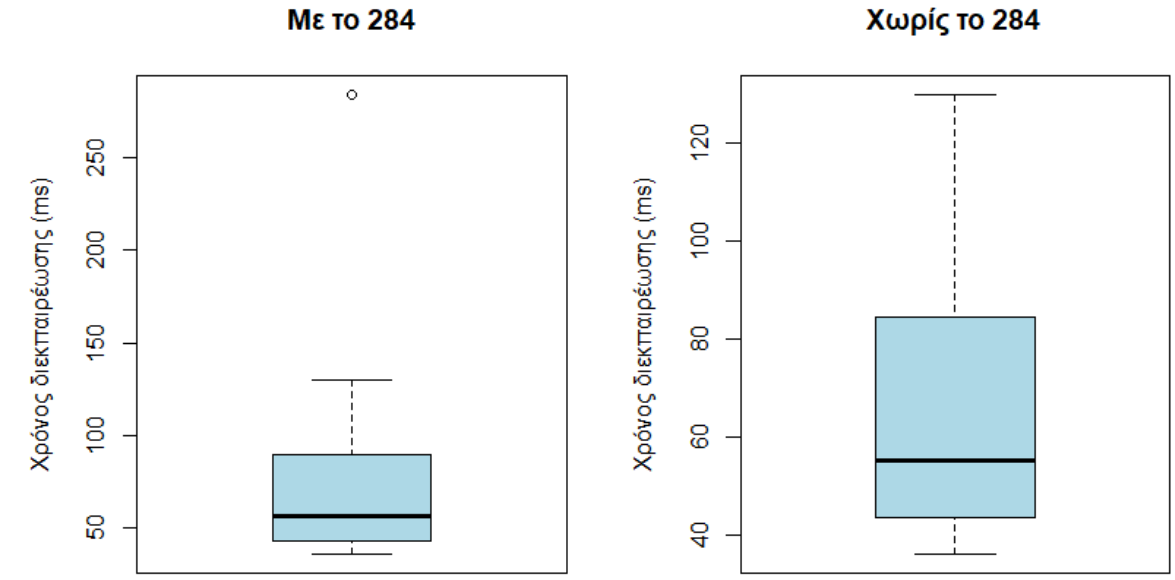
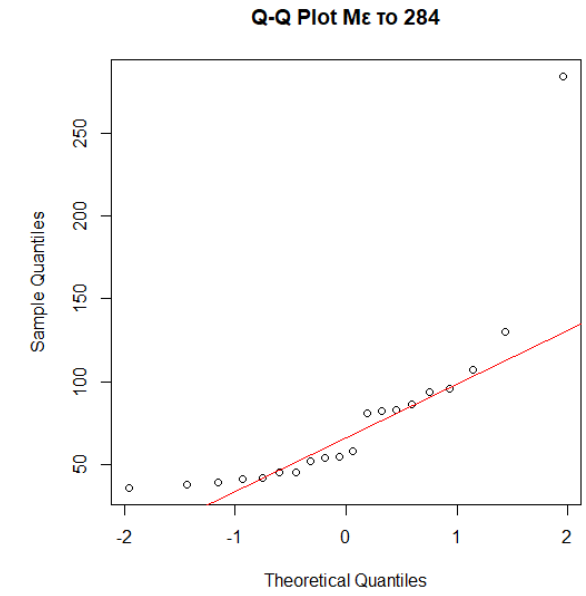
ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2024 – 2025
ΜΑΘΗΜΑ: ΣΤΑΤΙΣΤΙΚΗ ΣΤΗΝ ΠΛΗΡΟΦΟΡΙΚΗ
2η Άσκηση

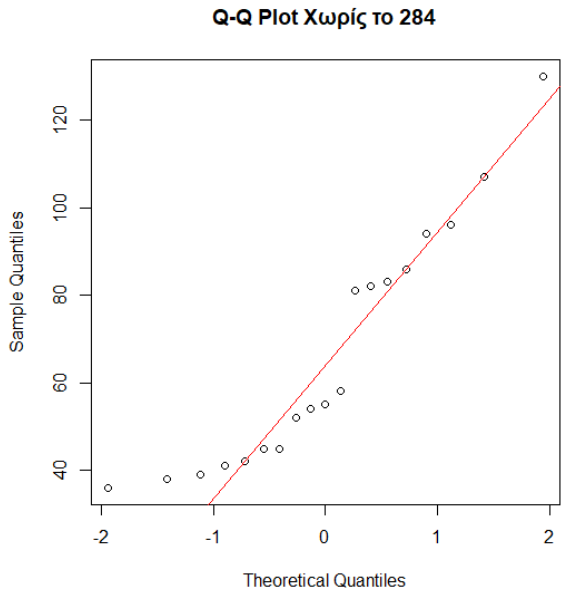
<u>Για όλους τους υπολογισμούς χρησιμοποιήθηκε η R</u>

Ερώτηση 1

a. Τα δεδομένα προέρχονται από τυχαία δειγματοληψία (SRS), το πλήθος των δεδομένων είναι μεγαλύτερο από 15. Το δείγμα δεν είναι κανονικά κατανεμημένο καθώς υπάρχει ένα ατυπικό σημείο (284), επίσης δεν είναι αρκετά μεγάλο ώστε να δικαιολογείται αυτό (20 < 40). Παρακάτω βλέπουμε τα διαγράμματα boxplot και Q-Q plot.







Θα προχωρήσουμε **αφαιρώντας το ατυπικό σημείο 284**, έτσι ώστε να εφαρμόσουμε μεθόδους συμπερασματολογίας στα δεδομένα μας, διαφορετικά τα αποτελέσματα δεν θα είναι ιδανικά. Τα δεδομένα είναι τώρα 19 (n=19), δεν είναι συμμετρικά όμως είναι σίγουρα πιο ορθά για να εξάγουμε συμπεράσματα.

b. Για το 95%διάστημα εμπιστοσύνης έχουμε $C: \bar{x} \pm t_* \frac{s}{\sqrt{n}}$, με τους παρακάτω υπολογισμούς:

```
data <- c(82, 55, 58, 94, 86, 45, 42, 36, 41, 130, 96, 39, 107, 52, 54, 45, 81, 83, 38)
sd <- sd(data)
mean <- mean(data)
message("Mean (x̄): ", mean)
t <- qt(0.975, 18)
message("t*: ", t)
message("Standard Deviation (s): ", sd)
ci <- t * sd / sqrt(19)
message("95% Confidence Interval: [", mean - ci, ", ", mean + ci, "]")
```

παίρνουμε:

```
Mean (x̄): 66.5263157894737
t*: 2.10092204024104
Standard Deviation (s): 27.5345609513503
95% Confidence Interval: [53.2550822233055, 79.7975493556419]
```

Σημειώνεται ότι το n είναι 19 και για τον υπολογισμό του t χρησιμοποιούμε βαθμούς ελευθερίας 18, δηλαδή n−1.

Αν δεν είχαμε αφαιρέσει το ατυπικό σημείο (284) θα είχαμε:

```
Mean (x̄): 77.4
95% Confidence Interval: [53.2550822233055, 79.7975493556419]
t*: 2.10092204024104
Standard Deviation (s): 55.5246744581561
95% Confidence Interval: [50.6379635643507, 104.162036435649]
```

Από όπου βλέπουμε ότι επηρεάζεται σημαντικά το πάνω όριο του 95% Confidence Interval.

Ερώτηση 2

a. Σύμφωνα με τον ορισμό, η τυπική απόκλιση του δειγματικού μέσου είναι : $\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$,

έτσι βλέπουμε ότι **λείπει η ρίζα από τον παρονομαστή**: : $\sigma_{\bar{x}} = \frac{12}{\sqrt{20}}$

b. Η μηδενική υπόθεση αφορά μόνο παραμέτρους του πληθυσμού και ΔΕΝ εξαρτάται από το δείγμα. Η υπόθεση $H_0: \bar{x} = 10$ **αναφέρεται στο δείγμα και όχι στον πληθυσμό**.

c. Για να απορριφθεί η μηδενική υπόθεση θα πρέπει ο δειγματικός μέσος να είναι μεγαλύτερος του 54, για να δεχτούμε την εναλλακτική υπόθεση. Εδώ όμως ο δειγματικός μέσος είναι 45 το οποίο είναι **μικρότερο** από το 54.

d. Η απόρριψη της μηδενικής υπόθεσης συμβαίνει μόνο αν το p value είναι μικρότερο από το επίπεδο σημαντικότητας α. Εδώ έχουμε p value=0.52 που σημαίνει ότι υπάρχει 52% πιθανότητα να εμφανιστούν παρόμοιες τιμές με το στατιστικό ελέγχου |z|, εφόσον ίσχυε η μηδενική υπόθεση. Συνήθως χρησιμοποιούνται οι τιμές α = 10%, 5% και 1%. Άρα **δεν απορρίπτουμε** την μηδενική υπόθεση αφού οι τιμές που έχουμε έχουν υψηλή πιθανότητα να είναι παρόμοιες.

Ερώτηση 3

Χρησιμοποιήθηκαν οι παρακάτω υπολογισμοί:

```
# Δεδομένο z
z <- 1.34

# Υπολογισμός p-value για κάθε περίπτωση
p_greater <- 1 - pnorm(z)          # Για H_a: μ > μ0
p_less <- pnorm(z)                 # Για H_a: μ < μ0
p_two_sided <- 2 * (1 - pnorm(z))  # Για H_a: μ ≠ μ0

# Εμφάνιση αποτελεσμάτων
message ("z: ", z)
message ("Φ(z): ", pnorm(z))
message ("p-value (1-Φ(z)): ", p_greater)

message ("z: ", z)
message ("Φ(z): ", pnorm(z))
message ("p-value (Φ(z)): ", p_less)

message ("z: ", z)
message ("Φ(z): ", pnorm(z))
message ("p-value ((2*Φ(-|z|)): ", p_two_sided)
```

a. Για Ha : $\mu > \mu_0$ το p-value μπορούμε να το υπολογίσουμε ως την πιθανότητα να βρούμε τιμές μεγαλύτερες από το z, έτσι έχουμε p-value (1-Φ(z)):

```
z: 1.34
Φ(z): 0.909877327535548
p-value (1-Φ(z)): 0.0901226724644524
```

b. Για Ha : $\mu < \mu_0$ το p-value μπορούμε να το υπολογίσουμε ως την πιθανότητα να βρούμε τιμές μικρότερες από το z, έτσι έχουμε p-value (Φ(z)):

```
z: 1.34
Φ(z): 0.909877327535548
p-value (Φ(z)): 0.909877327535548
```

c. Για Ha : $\mu \neq \mu_0$ το p-value υπολογίζεται διπλασιάζοντας την πιθανότητα να βρούμε τιμές μεγαλύτερες από την απόλυτη τιμή του z, έτσι έχουμε p-value (2*Φ(-|z|)):

```
z: 1.34
Φ(z): 0.909877327535548
p-value ((2*Φ(-|z|)): 0.180245344928905
```

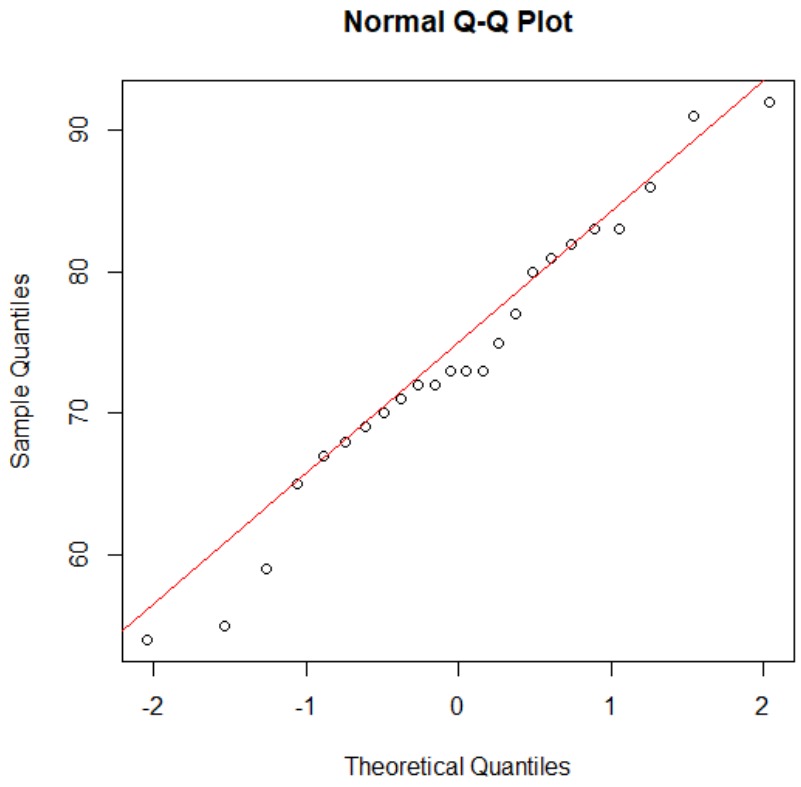
Ερώτηση 4

a. Για διάστημα εμπιστοσύνης 95% έχουμε επίπεδο σημαντικότητας α = 5% = 0.05, έτσι η μηδενική υπόθεση **απορρίπτεται** αφού p value = 0.04 < α = 0.05 και συνεπώς το 30 **δεν περιέχεται**.

b. Για διάστημα εμπιστοσύνης 90% έχουμε επίπεδο σημαντικότητας α = 10% = 0.10, έτσι η μηδενική υπόθεση απορρίπτεται αφού p value = 0.04 < α = 0.10 και συνεπώς το 30 **δεν περιέχεται** ούτε στο 90% διάστημα εμπιστοσύνης.

Ερώτηση 5

Σύμφωνα με την εκφώνηση, τα δεδομένα προήλθαν από απλή τυχαία δειγματοληψία (SRS). Παρατηρούμε όμως μία προφανώς λανθασμένη τιμή για το βάρος του υπ' αριθμόν 14 ατόμου (6 κιλά!). Επομένως θα αφαιρέσουμε αυτό το ατυπικό σημείο πριν προχωρήσουμε στην περαιτέρω ανάλυση τους. Έπειτα από την αφαίρεση της λανθασμένης τιμής, έχουμε n = 24 δείγματα, κάτι που καθιστά τα δεδομένα αυτά κατάλληλα καθώς το n είναι επαρκώς μεγάλο (n >= 15). Ο πληθυσμός επίσης φαίνεται να είναι κανονικά κατανεμημένος από το Normal QQ-plot.



a. Για 95% διάστημα εμπιστοσύνης για το μέσο βάρος των ενηλίκων της Αθήνας, από τον τύπο $C: \bar{x} \pm t_* \frac{s}{\sqrt{n}}$ και με τους παρακάτω υπολογισμούς:

```
data <- c(80, 81, 75, 83, 71, 73, 65, 67, 54, 77, 55, 83, 91, 92, 86, 73, 82, 69, 73, 70, 59,
68, 72, 72)
t <- qt(0.975, 23)
sd <- sd(data)
ci <- t * sd / sqrt(24)
mean <- mean(data)
message("Sample Size: ", length(data))
message("Mean: ", mean)
message("Standard Deviation: ", sd)
message("95% Confidence Interval: [", mean - ci, ", ", mean + ci, "]"
```

Παίρνουμε:

```
Sample Size: 24
Mean: 73.7916666666667
Standard Deviation: 9.97814641088722
95% Confidence Interval: [69.578264962991, 78.0050683703423]
```

b. Χωρίζουμε τα δεδομένα σε άνδρες και γυναίκες, οι άνδρες είναι 13 και οι γυναίκες είναι 11. Από τα παρακάτω stemplots βλέπουμε ότι τα δεδομένα δεν έχουν ασύμετρη μορφή και έτσι μπορούμε να προχωρήσουμε.

```
stem(men)
The decimal point is 1 digit(s) to the right of the |
6 | 8
7 | 2233
7 | 57
8 | 013
8 | 6
9 | 12

stem(women)
The decimal point is 1 digit(s) to the right of the |
5 | 459
6 | 579
7 | 013
8 | 23
```

Εφαρμόζουμε ξανά τον παραπάνω τύπο για την διαφορά των μέσων βαρών ανδρών και γυναικών και από τον παρακάτω κώδικα:

```
men <- c(80, 81, 75, 83, 73, 77, 91, 92, 86, 73, 68, 72, 72)
women <- c(71, 65, 67, 54, 55, 83, 73, 82, 69, 70, 59)

mmean <- mean(men)
wmean <- mean(women)
diff <- mmean - wmean
msd <- sd(men)
wsd <- sd(women)

#t <- -qt(0.1, 10)
#ci <- t * sqrt(msd^2 / 13 + wsd^2 / 11)

message("Men's Mean: ", mmean)
message("Women's Mean: ", wmean)
message("Difference of the Means: ", diff)
message("Men's Standard Deviation: ", msd)
message("Women's Standard Deviation: ", wsd)
message("t*: ", t)
message("80% Confidence Interval: [", diff - ci, ", ", diff + ci, "]")
```

Παίρνουμε:

```
Men's Mean: 78.6923076923077
Women's Mean: 68
Difference of the Means: 10.6923076923077
Men's Standard Deviation: 7.59807667971107
Women's Standard Deviation: 9.57078889120432
t*: 1.37218364111034
80% Confidence Interval: [5.78915526793254, 15.5954601166828]
```

c. Για να προχωρήσουμε στον έλεγχο για το αν έχει σχέση το κάπνισμα με το βάρος, θα θεωρήσουμε ότι η οποιαδήποτε σχέση δεν διαφοροποιείται μεταξύ ανδρών και γυναικών.

Χωρίζουμε τώρα τα δεδομένα σε καπνιστές και μη καπνιστές, υπάρχουν 10 καπνιστές και 14 μη καπνιστές.

Τα αντίστοιχα stemplot φαίνονται παρακάτω και εφόσον δεν έχουν ασύμετρη μορφή μπορούμε να προχωρήσουμε:

```
stem(smokers)

5 | 9
6 | 5
7 | 137
8 | 0236
9 | 2


stem(non smokers)
The decimal point is 1 digit(s) to the right of the |

5 | 45
6 | 789
7 | 022335
8 | 13
9 | 1
```

Έστω μ_s (smokers) το μέσο βάρος των καπνιστών και μ_{ns} (no smokers) το μέσο βάρος των μη καπνιστών. Στην συνέχεια παίρνουμε σαν μηδενική υπόθεση την:

Ho: $\mu_s = \mu_{ns}$ (Δεν υπάρχει διαφορά βάρους μεταξύ καπνιστών και μη)

και σαν ενναλακτική υπόθεση την:

Ha: $\mu_s \neq \mu_{ns}$ (Υπάρχει διαφορά βάρους μεταξύ καπνιστών και μη)

Χρησιμοποιώντας την συνάρτηση t.test() στον παρακάτω κώδικα:

```
smoker <- c(80, 83, 71, 73, 65, 77, 92, 86, 82, 59)
no_smoker <- c(81, 75, 67, 54, 55, 83, 91, 73, 69, 73, 70, 68, 72, 72)
sds <- sd(smoker)
nsd <- sd(data_no_smoke)
a <- (sds^2 )/ 10
b <- (nsd^2 ) / 14
z <- diff / sqrt(a + b)
t.test(smoker, no_smoker, alternative="two.sided", conf.level=0.95)
```

Βρίσκουμε ότι:

```
t = 1.2597, df = 19.281, p-value = 0.2228
```

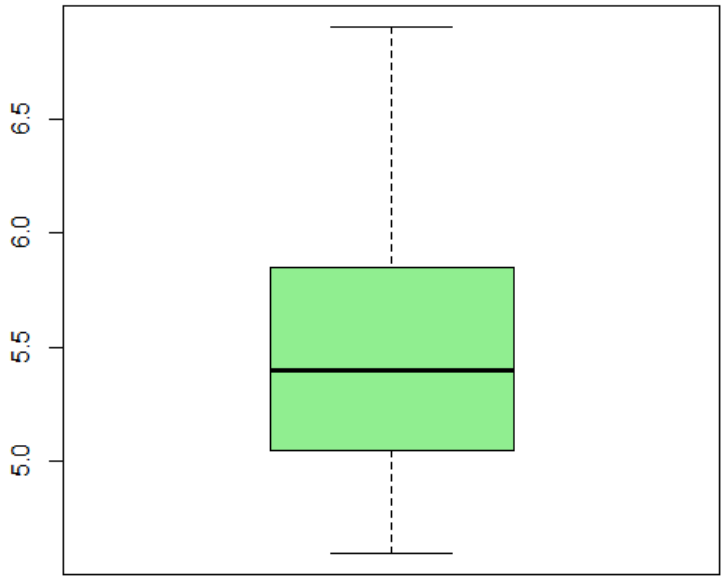
Το p_value είναι πολύ μεγάλο ώστε να απορρίψουμε την μηδενική υπόθεση (Ho). Άρα φαίνεται ότι **το κάπνισμα δεν έχει σχέση με το βάρος**.

Ερώτηση 6

a. Τα δεδομένα προέρχονται από τυχαία δειγματοληψία (SRS), δεν υπάρχουν ατυπικά σημεία και το πλήθος των δεδομένων είναι μεγαλύτερο από 15.

Παρακάτω βλέπουμε τα διαγράματα stemplot και boxplot που επιβεβαιώνουν ότι είναι συμμετρικά. Συνεπώς τα δεδομένα μας **είναι κατάλληλα** για τις μεθόδους συμπερασματολογίας που γνωρίζουμε.

```
The decimal point is at the |
  4 | 6999
  5 | 01233444467
  6 | 03349
```



b. Χρησιμοποιώντας τον παρακάτω κώδικα:

```
data <- c(5.7, 4.6, 6.4, 6.3, 6.9, 5.2, 4.9, 5.4, 4.9, 5.6, 5.4, 5.3, 4.9, 5.1, 5.0, 6.0, 6.3,
5.4, 5.3, 5.4)
mean(data)
sd(data)
message("Mean: ", mean(data))
message("Standard Deviation: ", sd(data))
```

Παίρνουμε:

Mean: 5.5
Standard Deviation: 0.600876552695267

c. Χρησιμοποιώντας τον παρακάτω κώδικα:

```
data <- c(5.7, 4.6, 6.4, 6.3, 6.9, 5.2, 4.9, 5.4, 4.9, 5.6, 5.4, 5.3, 4.9, 5.1, 5.0, 6.0, 6.3,
5.4, 5.3, 5.4)
t <- qt(0.975, 19)
ci <- t * sd(data) / sqrt(20)
message("95% Confidence Interval: [", mean(data) - ci, ", ", mean(data) + ci, "]")
```

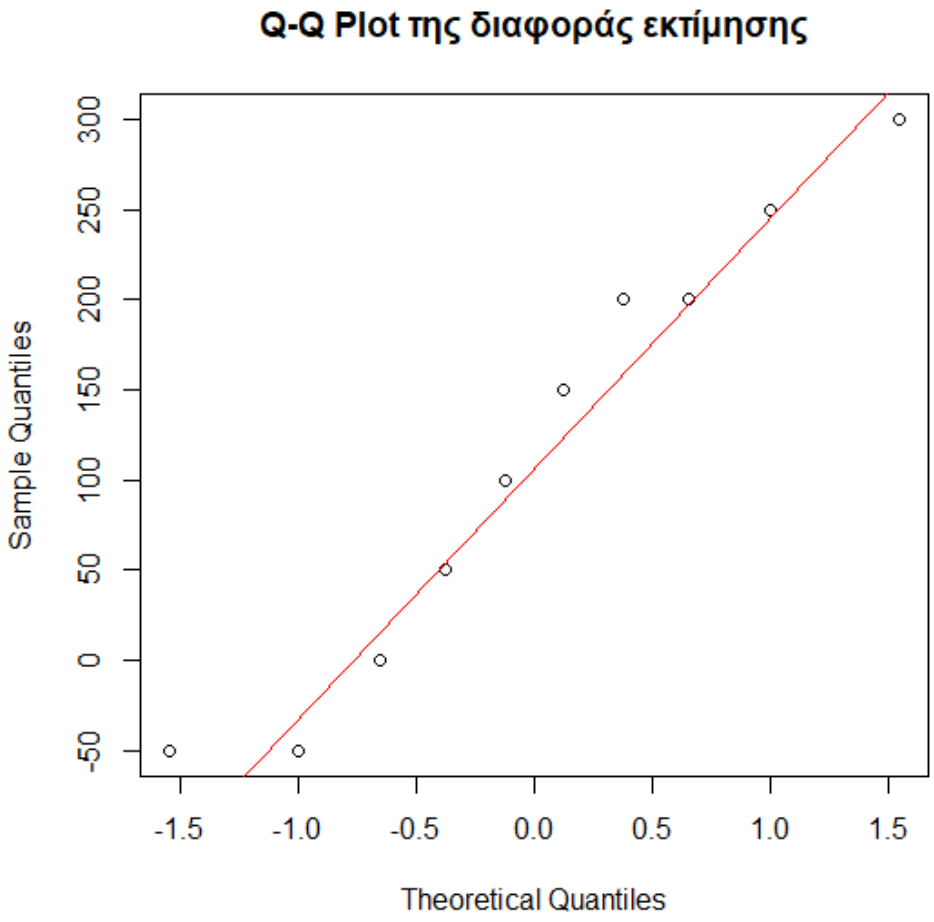
Παίρνουμε:

95% Confidence Interval: [5.21878111685868, 5.78121888314132]

Ερώτηση 7

Εδώ θα εφαρμόσουμε τεχνικές συμπερασματολογίας στην διαφορά της εκτίμησης ($d=x_{\text{Συνεργείο}} - x_{\text{Εμπειρογνώμονας}}$) για κάθε αυτοκίνητο.

Αν και το δείγμα είναι μικρό n=10 < 15, όμως παρατηρώντας το παρακάτω Normal QQ-plot βλέπουμε ότι ο πληθυσμός προσεγγίζει την κανονική κατανομή:



Στη συνέχεια θα εφαρμόσουμε το t-test. Κάνουμε τις εξής υποθέσεις:

H_0 : $\mu_d = 0$ (Δεν υπάρχει υπερεκτίμηση, δηλαδή η μέση διαφορά είναι μηδέν).

H_a : $\mu_d > 0$ (Υπάρχει υπερεκτίμηση, δηλαδή η μέση διαφορά είναι θετική).

Υπολογίζουμε τη διαφορά d_i για κάθε αυτοκίνητο, υπολογίζουμε τη μέση διαφορά $\bar{d}$ και την τυπική απόκλιση των διαφορών s_d, υπολογίζουμε το στατιστικό ελέγχου $t = \frac{\bar{d}}{s_d/\sqrt{n}}$, όπου n είναι το πλήθος των ζευγών (n=10).

Στην συνέχεια χρησιμοποιούμε την t-κατανομή με n−1 βαθμούς ελευθερίας (df = 9) και χρησιμοποιώντας των παρακάτω κώδικα:

```
# Δεδομένα
workshop <- c(500, 1550, 1250, 1300, 750, 1000, 1250, 1300, 800, 2500)
expert <- c(400, 1500, 1300, 1300, 800, 800, 1000, 1100, 650, 2200)

# Υπολογισμός διαφορών
differences <- workshop - expert

# Έλεγχος paired t-test
t_test_result <- t.test(differences, alternative = "greater", mu = 0)

# Εμφάνιση αποτελεσμάτων
t_test_result
```

παίρνουμε:

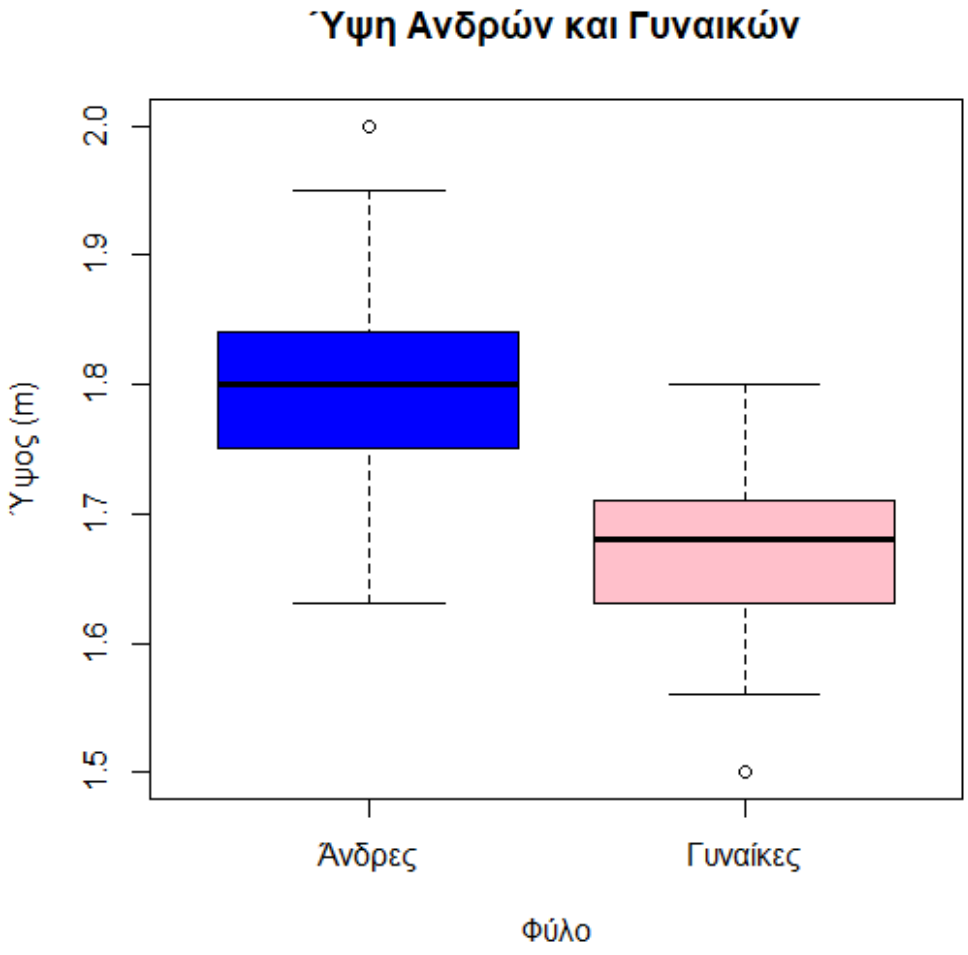
```
One Sample t-test

data:  differences
t = 2.9132, df = 9, p-value = 0.008611
alternative hypothesis: true mean is greater than 0
95 percent confidence interval:
 42.63653      Inf
sample estimates:
mean of x
      115
```

Από όπου φαίνεται ότι p-value < α (0.00861 < 0.05) και άρα απορρίπτεται η μηδενική υπόθεση και ισχύει η εναλλακτική. Επομένως πράγματι **το συνεργείο υπερεκτιμά τις ζημιές**. Κατά μέσο όρο, το συνεργείο εκτιμά 115 μονάδες παραπάνω σε σχέση με τον εμπειρογνώμονα.

Ερώτηση 8

a. Αρχικά θα πρέπει να δούμε αν τα δεδομένα του ερωτηματολογίου είναι κατάλληλα για τις μεθόδους συμπερασματολογίας που γνωρίζουμε. Τα δεδομένα προέρχονται από τυχαία δειγματοληψία (SRS), το πλήθος των δεδομένων είναι αρκετά μεγάλο: 137 φοιτητές από τους οποίους 49 φοιτητές έδωσαν φύλο F (γυναίκες) και 88 M (άνδρες). Ακολουθούν τα boxplots που μας δείχνουν ότι υπάρχει ένα ατυπικό σημείο στα ύψη των ανδρών και ένα ατυπικό σημείο στα ύψη των γυναικών. Αυτά τα ατυπικά σημεία δεν επηρεάζουν καθώς το πλήθος των δεδομένων είναι μεγάλο (137). Συνεπώς, με τις παραπάνω πληροφορίες, συμπεραίνουμε ότι μπορούμε να χρησιμοποιήσουμε μεθόδους συμπερασματολογίας σε αυτά.



Το 95% διάστημα εμπιστοσύνης για τη διαφορά του μέσου ύψους μεταξύ ανδρών και γυναικών φοιτητών πληροφορικής του ΟΠΑ το βρίσκουμε από τον παρακάτω κώδικα:

```
# Άσκηση 8 Ερώτημα a
data <- read.csv("c:/survey_data_2024_1.csv", header = TRUE, sep = ",", fill = TRUE)
# ύψος ανδρών

hm <- data$height[data$gender == 'M']

# ύψος γυναικών
hf <- data$height[data$gender == 'F']

t.test(hm,hf)
```

Και είναι:

```
95 percent confidence interval:
 0.1038985 0.1501413
```

b. Για να απαντήσουμε στο ερώτημα αυτό, αρχικά φιλτράρουμε τα δεδομένα και αφαιρούμε τους φοιτητές που δεν δηλώσει βαθμό στις Πιθανότητες (δηλαδή έχουν κενό στον βαθμό του μαθήματος).

Απομένουν 120 φοιτητές, εκ των οποίων 42 έδωσαν φύλο F (γυναίκες) και 78 φοιτητές M (άνδρες). Το δείγμα μας εξακολουθεί να είναι αρκετά μεγάλο και συνεπώς είναι καλό για μεθόδους συμπερασματολογίας.

Θέλουμε να συμπεράνουμε σε επίπεδο σημαντικότητας α = 5% εάν οι άνδρες επιτυγχάνουν μεγαλύτερο μέσο βαθμό (μM) στις Πιθανότητες από τις γυναίκες (μF). Κάνουμε τις εξής υποθέσεις:

$H_0 : \mu_M = \mu_F$ (οι μέσοι βαθμοί ανδρών και γυναικών είναι ίσοι).
$H_a : \mu_M > \mu_F$ (οι άνδρες έχουν μεγαλύτερο μέσο βαθμό από τις γυναίκες).

Και σε επίπεδο σημαντικότητας 5% (t.test):

```
data <- read.csv("c:/survey_data_2024_2.csv", header = TRUE, sep = ",", fill = TRUE)
# Διαχωρισμός βαθμών των ανδρών και των γυναικών
male_grades <- data$prob[data$gender == "M"]
female_grades <- data$prob[data$gender == "F"]

# Εκτέλεση t-test
t_test_result <- t.test(male_grades, female_grades, alternative = "greater")

# Εκτύπωση των αποτελεσμάτων
print(t_test_result)
```

παίρνουμε:

```
data:  male_grades and female_grades
t = 0.59925, df = 87.362, p-value = 0.2753
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 -0.5075867        Inf
sample estimates:
mean of x mean of y
 6.155128  5.869048
```

Παρατηρούμε πως το p-value είναι ίσο με 0.2753 και επειδή α=0.05, έχουμε p-value > α και συνεπώς **η μηδενική υπόθεση δεν απορρίπτεται**. Άρα **οι άνδρες φοιτητές δεν επιτυγχάνουν**

μεγαλύτερο μέσο βαθμό στο μάθημα Πιθανότητες από τι γυναίκες φοιτήτριες σε επίπεδο σημαντικότητας 5%.

c. Φιλτράρουμε τα δεδομένα και αφαιρούμε τους φοιτητές που δεν έχουν δηλώσει βαθμούς στις Πιθανότητες ή στα Μαθηματικά 1. Απομένουν 114 φοιτητές, τα δεδομένα μας είναι πολλά και συνεπώς μπορούμε να δοκιμάσουμε μεθόδους συμπερασματολογίας. Κάνουμε τις εξής υποθέσεις:

$H_0 : \mu_{\text{math}} = \mu_{\text{prob}}$ (οι μέσοι βαθμοί των δύο μαθημάτων είναι ίσοι).
$H_a : \mu_{\text{math}} \neq \mu_{\text{prob}}$ (οι μέσοι βαθμοί των δύο μαθημάτων διαφέρουν).
Εκτελούμε το t.test:

```
# Άσκηση 8 Ερώτημα c
data <- read.csv("c:/survey_data_2024_3.csv", header = TRUE, sep = ",", fill = TRUE)

# Παράμετροι
x <- data$math  # Βαθμοί στα Μαθηματικά
y <- data$prob  # Βαθμοί στις Πιθανότητες

# Paired t-test
t_test_paired <- t.test(x, y, paired = TRUE, alternative = "two.sided")

# Εμφάνιση αποτελεσμάτων
t_test_paired
```

και παίρνουμε:

```
data:  x and y
t = 3.115, df = 113, p-value = 0.002332
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 0.1768805 0.7950494
sample estimates:
mean difference
      0.4859649
```

Το p-value είναι μικρότερο από το επίπεδο σημαντικότητας α = 0.05. Αυτό σημαίνει ότι απορρίπτουμε τη μηδενική υπόθεση (H_0). Η εναλλακτική υπόθεση (Ha) δηλώνει ότι **υπάρχει διαφορά στους μέσους βαθμούς** ($\mu_{\text{math}} \neq \mu_{\text{prob}}$).

Το 95% διάστημα εμπιστοσύνης για τη διαφορά των μέσων ((μ_{math} - μ_{prob}) κυμαίνεται από 0.1769 έως 0.7950. Δεδομένου ότι το διάστημα δεν περιλαμβάνει το 0, υπάρχει στατιστικά σημαντική διαφορά. Η μέση διαφορά βαθμών είναι περίπου 0.486, με τους βαθμούς στα Μαθηματικά να είναι κατά μέσο όρο υψηλότεροι από τους βαθμούς στις Πιθανότητες.