ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2024 – 2025
ΜΑΘΗΜΑ: ΣΤΑΤΙΣΤΙΚΗ ΣΤΗΝ ΠΛΗΡΟΦΟΡΙΚΗ
3η Άσκηση

<u>Για τους υπολογισμούς χρησιμοποιήθηκε η R</u>

Ερώτηση 1

a. Πραγματοποιούμε άπειρες ρίψεις και παίρνουμε δείγμα από αυτές με n = 50 ρίψεις. Έστω X οι κορώνες και Y τα γράμματα με X = 29 και Y = 21. Το X > 15 και Y >15 άρα τα δεδομένα μας **είναι κατάλληλα** και επομένως μπορούμε να βγάλουμε διάστημα εμπιστοσύνης με ακρίβεια.

$$\hat{p} = \frac{X}{n} = \frac{29}{50} = 0.58$$

$$\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0.58 * 0.42}{50}} = 0.0697997135$$

Ζητείται 95% διάστημα εμπιστοσύνης (C=95%) οπότε έχουμε z_*=1.96 και το ζητούμενο διάστημα είναι: $\hat{p} \pm z_* \sigma_{\hat{p}} = [\mathbf{0.443192562}, \mathbf{0.716807438}]$

Θα μπορούσαμε να χρησιμοποιήσουμε τον παρακάτω κώδικα:

```
heads <- 29
tails <- 21
p <- 0.5
n <- 50
p_h <- heads / n

z <- qnorm(0.975)
ci <- z * sqrt(p_h * (1 - p_hat) / n)
message("95% Διάστημα Εμπιστοσύνης: [", p_h - ci, ", ", p_h + ci, "]")
```

Οπότε θα είχαμε το ίδιο φυσικά αποτέλεσμα:

```
95% Διάστημα Εμπιστοσύνης: [0.443195075474522, 0.716804924525478]
```

b. Έστω p η πιθανότητα εμφάνισης της κορώνας. Στην συνέχεια παίρνουμε σαν μηδενική υπόθεση την:

Ho: p = ½ (Δίκαιο νόμισμα)

και σαν ενναλακτική υπόθεση την:

Ha: p ≠ ½ (Μη δίκαιο νόμισμα)

Θα κάνουμε έλεγχο σημαντικότητας χρησιμοποιώντας στατικό έλεγχο z. Υπολογίζουμε το z από τον ακόλουθο τύπο:

$$z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0\,(1-p_0)}{n}}}$$

Όπου: $\hat{p} = 29/50$ $p_0 = 0.5$ n = 50. Έτσι προκύπτει z = 1.131371, επομένως μπορούμε να υπολογίσουμε το p-value ως p-value = 2Φ (-|z|), από όπου παίρνουμε **p-value = 0.257890**.

Θα μπορούσαμε να χρησιμοποιήσουμε τον παρακάτω κώδικα:

```
heads <- 29
tails <- 21
p <- 0.5
n <- 50
p_h <- heads / n
z <-(p_h - p) / sqrt(p * (1 - p) / n)
message("z: ", z)
pvalue <- 2 * pnorm(-z)
message("p-value: ", pvalue)
```

Οπότε θα είχαμε το ίδιο φυσικά αποτέλεσμα:

z: 1.13137084989848
p-value: 0.25789903529234

Έχουμε p-value = 0.257890 > α = 0.05 και συνεπώς η μηδενική υπόθεση δεν απορρίπτεται. **Άρα το νόμισμα είναι δίκαιο**.

c. Θέλουμε περιθώριο λάθους μικρότερο του 1%, (m = 0.01) άρα:

$$z_* \sqrt{\frac{p(1-p)}{n}} \leq m \Rightarrow n \geq \frac{{z_*}^2}{4m^2} \quad \Rightarrow \quad n \geq \mathbf{9604}$$

Θα μπορούσαμε να χρησιμοποιήσουμε τον παρακάτω κώδικα:

```
res <- (qnorm(0.975)^2) / (4*(0.01)^2)
message("Ρίψεις: ", round(res))
```

Οπότε θα είχαμε το ίδιο φυσικά αποτέλεσμα:

Ρίψεις: 9604

Ερώτηση 2

Σύμφωνα με τον τύπο που χρησιμοποιήσαμε και στην προηγούμενη άσκηση:

$$n \geq \frac{{z_*}^2}{4m^2}$$

Βλέπουμε ότι το μέγεθος του δείγματος δεν εξαρτάται από το μέγεθος του πληθυσμού, αλλά μόνο από το περιθώριο λάθους m και το επίπεδο εμπιστοσύνης και το Z_*. Έχουμε $Z_* = 1.96$ και m = 0.03, οπότε προκύπτει ότι **n >= 1068**.

Θα μπορούσαμε να χρησιμοποιήσουμε τον παρακάτω κώδικα:

```
n <- (qnorm(0.975)^2) / (4*(0.03)^2)
message("Δείγμα ατόμων: ", round(n) + 1)
```

Οπότε θα είχαμε το ίδιο φυσικά αποτέλεσμα:

Δείγμα ατόμων: 1068

Έτσι λοιπόν επειδή δεν έχουμε κάποια αλλαγή στο επίπεδο εμπιστοσύνης και στο περιθώριο σφάλματος ο αριθμός των ατόμων που θα πάρουν μέρος στην δημοσκόπηση για την Αμερική θα είναι ο ίδιος όπως και στην Ελλάδα. Παρά την μεγάλη διαφορά στον πληθυσμό των 2 χωρών εμείς απλά ψάχνουμε πόσα άτομα (παράμετρος n) θα πρέπει να χρησιμοποιηθούν στην δημοσκόπηση.

Αυτό δεν επηρεάζεται από τον συνολικό πληθυσμό αλλά από το διάστημα εμπιστοσύνης και το περιθώριο σφάλματος.

Ερώτηση 3

Χρησιμοποιήθηκαν οι παρακάτω υπολογισμοί:

```
data <- read.csv("c:/askisi3.csv")

males <- subset(data, SEX == 'M')
males_s <- subset(males, SMOKER == 'YES')
males_no <- subset(males, SMOKER == 'NO')

females <- subset(data, SEX == 'F')
females_s <- subset(females, SMOKER == 'YES')
females_no <- subset(females, SMOKER == 'NO')

message("Άντρες καπνιστές: ", nrow(males_s))
message("Άντρες μη καπνιστές: ", nrow(males_no))
message("Γυναίκες καπνιστές: ", nrow(females_s))
message("Γυναίκες μη καπνιστές: ", nrow(females_no))

pM <- nrow(males_s) / nrow(subset(data, SEX == 'M'))
pF <- nrow(females_s) / nrow(subset(data, SEX == 'F'))
p <- (nrow(females_s) + nrow(males_s)) / nrow(data)

message("Πιθανότητα να είναι καπνιστής ένας άντρας: ", pM)
message("Πιθανότητα να είναι καπνιστής μία γυναίκα: ", pF)
message("Πιθανότητα να είναι καπνιστής ένας άνθρωπος: ", p)

z <- (pF - pM) / sqrt(p * (1 - p) / nrow(females) + p * (1 - p) / nrow(males))
message("z: ", z)

pval <- 2 * pnorm(-z)
message("p-value: ", pval)

c <- (pF-pM)+c(-1,1)*(-1)*qnorm(0.025)*sqrt(pF*(1-pF)/sum(SEX == 'F')+pM*(1- pM)/sum(SEX == 'M'))
message("95% Διάστημα Εμπιστοσύνης: [", c[1], ", ", c[2], "]")

ta <- table(SMOKER, SEX)

addmargins(ta)

chisq.test(ta, correct = FALSE)
```

a. Σύμφωνα με την εκφώνηση, τα δεδομένα προήλθαν από απλή τυχαία δειγματοληψία (SRS) και είναι περισσότερα του 5 σε κάθε περίπτωση:

Άντρες καπνιστές: 12
Άντρες μη καπνιστές: 18
Γυναίκες καπνιστές: 14
Γυναίκες μη καπνιστές: 16

επομένως αποτελούν καλά δεδομένα για να εφαρμόσουμε έλεγχο σημαντικότητας.

Έστω pM και pF οι πιθανότητες να καπνίζει ένας άντρας και μία γυναίκα αντίστοιχα. Θέλουμε να εξετάσουμε εάν υπάρχει σχέση μεταξύ φύλου και καπνίσματος, έτσι παίρνουμε σαν μηδενική υπόθεση την:

Ho: pM = pF (το κάπνισμα δεν εξαρτάται από το φύλλο)

και σαν ενναλακτική υπόθεση την:

Ha: pM ≠ pF (το κάπνισμα εξαρτάται από το φύλο)

Θα κάνουμε έλεγχο σημαντικότητας χρησιμοποιώντας στατικό έλεγχο z. Υπολογίζουμε το z από τον ακόλουθο τύπο:

$$Z = \frac{\widehat{p_1} - \widehat{p_2}}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n_1} + \frac{\hat{p}(1-\hat{p})}{n_2}}}$$

Από τον παραπάνω κώδικα παίρνουμε:

```
Πιθανότητα να είναι καπνιστής ένας άντρας: 0.4
Πιθανότητα να είναι καπνιστής μία γυναίκα: 0.466666666666667
Πιθανότητα να είναι καπνιστής ένας άνθρωπος: 0.433333333333333

z: 0.521050105718906
p-value: 0.602331867061728
```

Για διάστημα εμπιστοσύνης 95%, έχουμε α=5% και επομένως p-value > α και συνεπώς η μηδενική υπόθεση δεν απορρίπτεται και άρα **το κάπνισμα δεν εξαρτάται από το φύλλο**.

b. Όπως είπαμε και στην περίπτωση a, τα δεδομένα προήλθαν από απλή τυχαία δειγματοληψία (SRS) και είναι αρκετά (> 10), έτσι μπορούμε να υπολογίσουμε ακριβές διάστημα εμπιστοσύνης 95% χρησιμοποιώντας τον τύπο:

$$\widehat{p_1} - \widehat{p_2} \pm Z_* \sqrt{\frac{\widehat{p_1}(1-\widehat{p_1})}{n_1} + \frac{\widehat{p_2}(1-\widehat{p_2})}{n_2}}$$

Από τον παραπάνω κώδικα παίρνουμε:

```
95% Διάστημα Εμπιστοσύνης: [-0.183536353203303, 0.316869686536636]
```

c. Για να είναι ακριβής ο έλεγχος σημαντικότητας θα πρέπει τα δεδομένα μας να προέρχονται από απλό τυχαίο δείγμα (SRS). Στη συγκεκριμένη περίπτωση έχουμε ένα απλό τυχαίο δείγμα και τα δεδομένα μας είναι ανεξάρτητα. Οπότε μπορούμε να προχωρήσουμε σε έλεγχο σημαντικότητας. Έστω οι κατηγορικές μεταβλητές SEX (για το φύλο) και SMOKER (για το κάπνισμα). Έστω η μηδενική υπόθεση:

Ho: το φύλο δεν σχετίζεται με το κάπνισμα

και η εναλλακτική υπόθεση

Ha: το φύλο σχετίζεται με το κάπνισμα.

Ο πίνακας συνάφειας για τα δεδομένα του Πίνακα 1 είναι:

```
       SEX
SMOKER  F  M Sum
   N   16 18  34
   Y   14 12  26
   Sum 30 30  60
```

d. Από τον παραπάνω κώδικα παίρνουμε:

```
        Pearson's Chi-squared test

data:  ta
X-squared = 0.27149, df = 1, p-value = 0.6023
```

Άρα p-value = 0.6023. Για διάστημα εμπιστοσύνης 95% έχουμε α = 0.05 και άρα p-value = 0.6023 > 0.05=α, οπότε δε μπορούμε να απορρίψουμε την μηδενική υπόθεση. **Άρα οι μεταβλητές**

φύλο και κάπνισμα είναι ανεξάρτητες, δηλαδή το φύλο δε σχετίζεται με το κάπνισμα. Παρατηρούμε ότι η τιμή αυτή είναι **ίση με την τιμή του p-value που υπολογίσαμε στο ερώτημα a**.

Ερώτηση 4

Έχουμε απλό τυχαίο δείγμα, τα δεδομένα προήλθαν από απλή τυχαία δειγματοληψία (SRS) και αρκετά δείγματα (>10)**.**

a. Έστω η μηδενική υπόθεση:

Ho: παρασκευάζονται ίσες ποσότητες κόκκινων και μπλε smarties, $p_K = p_M$

και η ενναλακτική υπόθεση:

Ha: παρασκευάζονται περισσότερα κόκκινα smarties, $p_K > p_M$

Θα χρησιμοποιήσουμε την συνάρτηση prop.test της R (ουσιαστικά z έλεγχος για 1 δείγμα), το οποίο θα ελέγξει τα ποσοστά για το 1 δείγμα που έχουμε στην διάθεσή μας και θα μας δώσει το p-value, χρησιμοποιώντας τον παρακάτω κώδικα:

```
prop.test(x=19, n=34, alternative="greater", conf.level=0.95, correct=FALSE)
```

Παίρνουμε:

```
    1-sample proportions test without continuity correction

data:  19 out of 34, null probability 0.5
X-squared = 0.47059, df = 1, p-value = 0.2464
alternative hypothesis: true p is greater than 0.5
95 percent confidence interval:
 0.4196133 1.0000000
sample estimates:
        p
0.5588235
```

Έτσι έχουμε α=5%, και p-value = 0.2464 > α=0.05. Η μηδενική υπόθεση H_o δεν μπορεί να απορριφθεί και άρα **δεν παράγονται περισσότερα κόκκινα smarties από ότι μπλε**.

b. Έστω η μηδενική υπόθεση:

Ho: η κατανομή των χρωμάτων καφέ, κόκκινο, κίτρινο, μπλε και πράσινο είναι 19.8%, 17.8%, 17.6%, 19.6%, 25.2% αντίστοιχα

και η ενναλακτική υπόθεση:

Ha: η κατανομή χρωμάτων δεν είναι η παραπάνω

Θα χρησιμοποιήσουμε την συνάρτηση prop.test της R (ουσιαστικά z έλεγχος για 1 δείγμα), το οποίο θα ελέγξει τα ποσοστά για το 1 δείγμα που έχουμε στην διάθεσή μας και θα μας δώσει το p-value, χρησιμοποιώντας τον παρακάτω κώδικα:

```
q <- c(22, 19, 16, 15, 8)
p <- c(0.198, 0.178, 0.176, 0.196, 0.252)
chisq.test(q, p=p)
```

Παίρνουμε:

```
            Chi-squared test for given probabilities

data:  q
X-squared = 11.613, df = 4, p-value = 0.02048
```

Έχουμε p-value = 0.02048 < α = 0.05 (για διάστημα εμπιστοσύνης 95%). Συνεπώς η μηδενική υπόθεση απορρίπτεται. **Άρα η κατανομή έχει αλλάξει από το 2009**.

c. Έστω η μηδενική υπόθεση:

Ho: Smarties και M&Ms έχουν ίδια αναλογία χρωμάτων

και η ενναλακτική υπόθεση:

Ha: οι αναλογίες χρωμάτων Smarties και M&Ms να διαφέρουν

Θα χρησιμοποιήσουμε Χρησιμοποιούμε τον έλεγχο χ^2 για δύο δείγματα, χρησιμοποιώντας τον παρακάτω κώδικα:

```
# Δεδομένα
smarties <- c(22, 19, 16, 15, 8)
mms <- c(10, 12, 20, 9, 5)

# Δημιουργία πίνακα παρατηρήσεων
observed <- rbind(smarties, mms)

# Εκτέλεση ελέγχου chi-squared
result <- chisq.test(observed)

# Εμφάνιση αποτελεσμάτων
print(result)
```

Παίρνουμε:

```
        Pearson's Chi-squared test

data:  observed
X-squared = 4.6262, df = 4, p-value = 0.3278
```

Έχουμε α=5%, και p-value = 0.3278 > α=0.05 και συνεπώς η μηδενική υπόθεση δεν μπορεί να απορριφθεί, άρα **τα Smarties και τα M&Ms έχουν την ίδια αναλογία χρωμάτων**.